#### **GENÒMICA COMPUTACIONAL. PEC2**

Amèlia Martínez Seguera. Maig 2020.

## Exercici 1. Estratègies d'alineament.

## 1. Alineament global de les seqüències CDS del gen TMEM106B (humà) i el gen tmem106b (ratolí) amb CLUSTAL.

Obtenim les dues seqüències CDS amb el navegador GenomeBrowser de UCSC (veure seqüències obtingudes a <u>annex1a</u>). Observem que existeixen dues variants del gen TMEM106B humà (isoformes):

```
>hg38_refGene_NM_018374 range=chr7:12214811-12231975 5'pad=0 3'pad=0 strand=+
repeatMasking=none
>hg38_refGene_NM_001134232 range=chr7:12214811-12231975 5'pad=0 3'pad=0 strand=+
repeatMasking=none
```

# Sequence Retrieval Region Options: Promoter/Upstream by 5000 bases 5' UTR Exons CDS Exons 3' UTR Exons Introns Downstream by 1000 bases One FASTA record per gene. One FASTA record per region (exon, intron, etc.) wit Split UTR and CDS parts of an exon into separat Note: if a feature is close to the beginning or end of a c

CLUSTAL permet fer l'alineament global de dos o més seqüències. Efectúa la correspondència entre les seqüències completes, maximitzant el número total de caracters coincidents. Aquest alineament global està indicat per efectuar comparacions entre seqüències que a priori codifiquen elements amb una funció biològica semblant i que,possiblement, tenen una mida i estructura similars. Per exemple, com en el nostres cas, el mateix gen en dues espècies diferents, o proteines homòlogues. En funció de la distància evolutiva entre les dues espècies comparades, trobarem més o menys simil.litud.

Si comparem les 3 seqüències:

S'observa un 100% d'identitat entre les dues isoformes del gen humà, i un 88.85% d'identitat entre qualsevol de les dues humanes amb la de ratolí (Veure resultat alineament complet en <u>annex 1b</u>):

```
Percent Identity Matrix - created by Clustal2.1

1: hg38_refGene_NM_018374 100.00 88.85
2: mm10_refGene_NM_027992 88.85 100.00
```

2. Mateix alineament global de les proteïnes amb CLUSTAL. Grau d'homologia entre seqüències.

Obtenim les seqüències de la proteïna amb "Predicted Protein" a GenomeBrowser d'UCSC (veure seqüències obtingudes en annex2) :

#### Links to sequence:

- · Predicted Protein
- mRNA Sequence (may be different from the genomic sequence)
- · Genomic Sequence from assembly
- · CDS FASTA alignment from multiple alignment

#### I tornem a realitzar l'alineament amb CLUSTAL:

```
CLUSTAL O(1.2.4) multiple sequence alignment
```

NP_060844 NP_082268	MGKSLSHLPLHSSKEDAYDGVTS-ENMRNGLVNSEVHNEDGRNGDVSQFPYVEFTGRDSV MGKSLSHLPLHSNKEDGYDGVTSTDNMRNGLVSSEVHNEDGRNGDVSQFPYVEFTGRDSV	59 60
NP_060844 NP_082268	TCPTCQGTGRIPRGQENQLVALIPYSDQRLRPRRTKLYVMASVFVCLLLSGLAVFFLFPR TCPTCQGTGRIPRGQENQLVALIPYSDQRLRPRRTKLYVMASVFVCLLLSGLAVFFLFPR	119 120
NP_060844 NP_082268	SIDVKYIGVKSAYVSYDVQKRTIYLNITNTLNITNNNYYSVEVENITAQVQFSKTVIGKA SIEVKYIGVKSAYVSYDAEKRTIYLNITNTLNITNNNYYSVEVENITAQVQFSKTVIGKA *:***********************************	179 180
NP_060844 NP_082268	RLNNITIIGPLDMKQIDYTVPTVIAEEMSYMYDFCTLISIKVHNIVLMMQVTVTTTYFGH RLNNITNIGPLDMKQIDYTVPTVIAEEMSYMYDFCTLLSIKVHNIVLMMQVTVTTAYFGH	239 240
NP_060844 NP_082268	SEQISQERYQYVDCGRNTTYQLGQSEYLNVLQPQQ 274 SEQISQERYQYVDCGRNTTYQLAQSEYLNVLQPQQ 275	

El grau d'homologia entre les dues seqüències de la proteïna es d'un 95.99%.

Com hem dit abans, el gen TMEM106B humà té dues isoformes, però les proteïnes resultants són iguals:

Per tant, la homologia amb tmem106b és la mateixa:

L'alt percentatge d'identitat ens indica que existein una gran homologia entre les dues proteïnes, com és d'esperar quan es fa un alineament global entre proteïnes que resulten del mateix gen de dues espècies diferents. La semblança serà més evident si existeix menor distància evolutiva, per exemple en aquest cas, on tots dos organismes són mamífers. L'augment d'identitat entre proteïnes respecte a la seqüència CDS és deguda a que hi ha canvis evolutius als gens (mutacions puntuals) que no són relevants per la funció de la proteïna. Un exemple serien les mutacions silencioses, al tercer nucleòtid del codó. A més, existeixen aa amb propietats simil.lars que es poden intercanviar dins de la proteïna sense alterar el producte final.

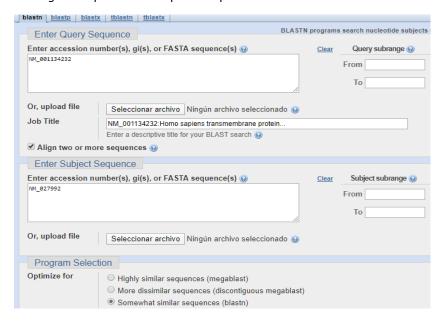
## 3. Alineament local amb BLAST de les dues seqüències CDS.

BLAST fa servir un "diccionari" de paraules per identificar quines seqüències de la seva base de dades seran més simil.lars a la nostra. En el problema que se ns planteja, triarem l'opció blastn, que serveix per alinear seqüències de nucleòtids curtes i fer comparacions entre espècies, com és el nostre cas.

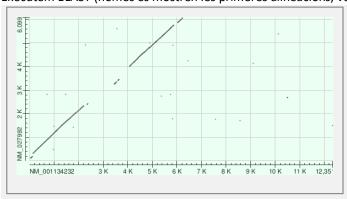
Table 1. Key features of the BLAST search pages in the "Basic BLAST" category

Search page	Query & database	Alignment	Programs & functions (default program in bold)
nucleotide blast	nucleotide vs nucleotide	Nucleotide	megablast: for sequence identification, intra-species comparison discontiguous megablast: for cross-species comparison, searching with coding sequences blastn: for searching with shorter queries, cross-species comparison
protein blast	Protein vs protein	protein	blastp: general sequence identification and similarity searches Quick BLASTP: with a kmer match to accelerate search speed for very similar proteins DELTA-BLAST [3]: protein similarity search with higher sensitivity than blastp PSI-BLAST: iterative search for position-specific score matrix (PSSM) to identify distant relatives for a protein family PHI-BLAST: protein alignment with input pattern as anchor/constraint
blastx	nucleotide (tr) vs protein	protein	<u>blastx</u> : for identifying potential protein products encoded by a nucleotide query
tblastn	protein vs nucleotide (tr)	protein	tblastn: for identifying database sequences encoding proteins similar to the query
tblastx	nucleotide (tr) vs nucleo- tide (tr)	protein	<u>tblastx</u> : for identifying nucleotide sequences similar to the query based on their coding potential

Marquem "Align two or more sequences" per fer la comparació. Cambiem el "Program Selection" per defecte a blastn, i deixem els "Algorithm parameters" que hi ha per defecte:



Executem BLAST (només es mostren les primeres alineacions, veure arxiu complet en annex3):



```
RID: B5G0BE69114
Job Title:NM 001134232:Homo sapiens transmembrane protein...
Subject:Mus musculus transmembrane protein 106B (Tmem106b), mRNA ID: NM_027992.3(nucleic acid) Length: 6099
Query #1: Homo sapiens transmembrane protein 106B (TMEM106B), transcript variant 2, mRNA Query ID: ref|NM_001134232.2 Length: 12351
Sequences producing significant alignments:

        Max
        Total Query
        E
        Per.

        Score
        Score cover
        Value
        Ident
        Accession

        1501
        2771
        37%
        0.0
        76.41
        NM_027992.3

Description
Mus musculus transmembrane protein 106B (Tmem106b), mRNA
Alignments:
>Mus musculus transmembrane protein 106B (Tmem106b), mRNA
Sequence ID: NM_027992.3 Length: 6099
Range 1: 310 to 2346
Score: 1501 bits(1664), Expect: 0.0,
Identities:1623/2124(76%), Gaps:126/2124(5%), Strand: Plus/Plus
              ACATGGGAAAGTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGCTTATGATG 192
              Sbjct 310
              ACATGGGAAAGTCTCTTTCTCACTTACCTTTGCATTCAAATAAAGAAGATGGCTATGATG
Query 193
              GAGTCACATCT - - - GAAAACATGAGGAATGGACTGGTTAATAGTGAAGTCCATAATGAAG
                                                                                  249
              Shict 370
```

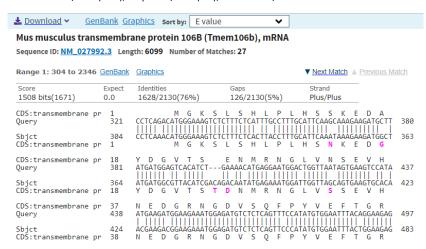
Observem que hi ha un 76% d'identitat. Si realitzem la mateixa alineació però amb l'altre variant del gen, obtenim resultats semblants(veure annex 2):

>Mus musculus transmembrane protein 106B (Tmem106b), mRNA

Sequence ID: NM\_027992.3 Length: 6099

Score:1508 bits(1671), Expect:0.0,

Identities:1628/2130(76%), Gaps:126/2130(5%), Strand: Plus/Plus



Blastn ens proporciona diferents alineaments, amb diferents puntuacions o *scores*. És un alineament local que realitza exclusivament la correspondència entre aquells fragments de les seqüències que tenen coincidència màxima de caracters, descartant la resta de regions que no presenten mínima simil.litud. Així com sempre és possible obtenir un alineament global, és poc freqüent identificar alineaments locals si no existeix certa conservació funcional.Com hem dit abans, per comparar un mateix gen o proteïnes homòlogues entre diferents espècies, és millor utilitzar un programa d'alineament global com, per exemple, CLUSTAL.

## 4. Alineament global amb CLUSTAL de genomicA.txt i genomicB.txt.

En aquestes dues seqüències les lletres minúscules representen la regió no traduïble, i les majúscules ens indiquen els fragments codificants, que comencen per ATG. Alineem globalment totes dues seqüències amb CLUSTALO, i obtenin el següent resultat

```
Percent Identity Matrix - created by Clustal2.1

1: genomicA 100.00 44.09
2: genomicB 44.09 100.00
```

(veure alineament complet en annex4).

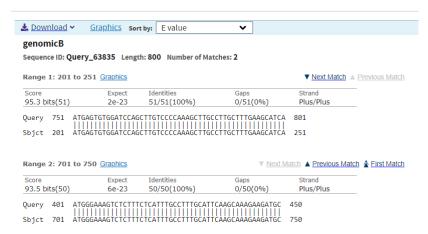
Observem que el percentatge d'identitat és baix, i que hi ha coincidència de regions codificants d'una seqüència amb no codificants de l'altre.

#### Alineament local amb BLAST de genomicA.txt i genomicB.txt.

En aquest cas, farem servir la funció *megablast*, que està recomanada per comparacions intraespecífiques. Es tracta d'un alineament múltiple local que efectúa únicament la correspondència entre aquells fragments que tenen una coincidència relevant, descartant la resta de regions.



Com és un alineament local, el BLAST troba dues coincidències, amb una identitat del 100% entre A i B (veure annex5):



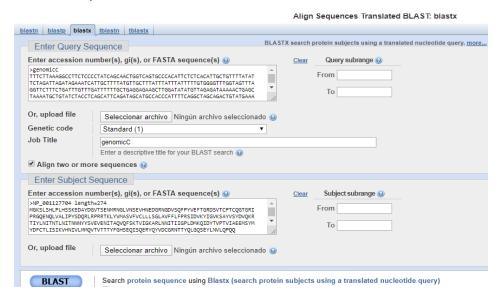
#### 6. Quin programa és més adequat per cada comparació?

El programa CLUSTAL fa alineaments globals, per tant és més addient per fer comparacions de seqüències que codifiquen elements que a priori tenen una funció biològica semblant i que, per tant, tenen una mida i estructura simil.lars. Per exemple, les comparacions inter-específiques d'un mateix gen, o seqüències d'aa. de dues proteïnes homòlogues.

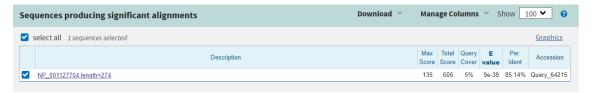
En canvi, BLAST fa alineaments locals, per tant estaria indicat per comparar seqüències on el seu contingut, en general, no està altament conservat, com les regions reguladores o dominis funcionals específics en proteïnes. En canvi, l'alineament local realitza exclusivament correspondències entre aquells fragments de les seqüències que tenen coincidència màxima, descartant les altres regions. L'alineament local es addient per identificar elements de petit tamany conservats dins un context general divers. Aquests elements possiblement estan relacionats amb la configuració de dominis de proteïnes o llocs d'unió a factors de transcripció (TFs).

## Alineament d´una seqüència de nucleòtids de pollastre, genomeC, amb una seqüència de proteïna de TMEM106B humana.

En aquest cas, fem servir blastx, que identifica proteïnes potencials, codificades dins d una seqüència "consulta" de nucleòtids. Processa totes les possibles proteïnes codificades dintre de la seqüència problema, fent servir una matriu de substitució per recuperar aquells aa que produeixen un canvi sinònim (veure <u>annex6</u>, per resultat complet de l'alineament. Només s'han inclòs els *scores* més alts):



Trobem que genomeC té un 85.14% de coincidència amb NP\_001127704 (amb un E value significatiu), que és una de les isoformes de TMEM106B en humans:



Les regions que tenen un alt percentatge d'identitat, estarien implicades en funcions biològiques comuns entre les dues espècies, que s'han conservat al llarg de l'evolució. Aquesta identitat correspòn a una possible seqüència ancestral comú. Aquesta simil.litud és més gran que si haguèssim comparat les dues seqüències de nucleòtids, ja que, com hem dit anteriorment, blastx té en compte els canvis sinònims(que no impliquen canvi d'aa).

## 8. Programa MEME. Estudi de la regulació gènica mitjançant factors de transcripció.

MEME descobreix *motius* o patrons de seqüència que es produeixen repetidament en un grup de seqüències. Representa una alternativa a altres aplicacions que busquen llocs d'unió a factors de transcripció. Es basa en la identificació de motius conservats en grups de seqüències: busca iteracions dins de la seqüència i després les compara amb catàlegs d'informació coneguda. MEME representa aquests motius com a matrius que descriuen la probabilitat de cada lletra possible en cada posició del patró. Els motius MEME individuals no contenen *gaps*. MEME divideix els patrons de longitud variable en dos o més motius separats, i tracta tots els caràcters ambigus en seqüències com comodins que coincideixen amb totes les lletres.

Es prèn com a *input* un grup de seqüències que hipotèticament comparteixen algun mecanisme de regulació i com a *output* tants motius com se sol·liciti. Utilitza tècniques estadístiques per triar automàticament l'amplada, el nombre de casos, i la millor descripció per a cada motiu. També podem afegir un segon *input*(control) de seqüències i descobrir motius del conjunt primari en relació al conjunt de control. Això s'anomena *descobriment de motius discriminatoris*.

Bailey i Elkan, a "Fitting a mixture model by expectation maximization to discover motifs in biopolymers" (California, 1994) expliquen que MEME ha implementat l'algoritme MM per descobrir múltiples motius en seqüències de DNA. A partir d'una serie de seqüències de biopolímers no alineats i possiblement relacionats, estima els paràmetres d'un model probabilístic mixte de dos components. Un component descriu una sèrie de subseqüències similars de determinada amplitud (el "motiu"), i l'altre component descriu totes les altres posicions en le seqüències (el "background"). Ajustar el model inclou estimar la freqüència relativa de motius, i aquesta freqüència determina el llindar per a una òptima classificació bayesiana que podrà ser emprada per trobar motius en altres dades. L'algoritme només requereix una sèrie de seqüències no alineades i especificar l'amplada del

motius. Aleshores, estima quin nombre de cops apareix cada motiu en cada seqüència i ens retorna un alineament d'aquestes repeticions. És capaç de descobrir diferents motius amb diferents freqüències d'aparició en una única base de dades.

#### 9. Regulació transcripcional de TMEM106B al llarg de l'evolució. Regió promotora del gen.

Les regions promotores d'un gen són "interruptors" que s'accionen per diferents TFs. Els TFs són proteïnes amb un domini per detectar llocs d'unió al DNA. Aquests llocs d'unió són seqüències de 5-15 nucleòtids, que són reconeguts normalment per més d'un TF. Les regions reguladores poden estar ubicades inmediatament abans del gen (promotor basal), o a uns pocs milers de bases (promotor proximal). Obtenim la regió promotora de TMEM106B humà (hg38) emprant les anotacions de RefSeq en el navegador d'UCSC (5000 nucleòtids upstream):

Se	equence Retrieval F	Re	gion C	ptions:
✓	Promoter/Upstream by	50	00	bases
	5' UTR Exons			
	CDS Exons			
	3' UTR Exons			
	Introns			
	Downstream by 1000		bases	
	One FASTA record per	ge	ne.	
•	One FASTA record per	reg	jion (ex	on, intron, etc.) w
	■ Split UTR and CDS :	oai	ts of ar	exon into separa
No	ite: if a feature is close t	o t	he begi	nning or end of a

#### (Veure regions promotores que hem obtingut a annex7)

#### 10. MEME. Busquem en les 4 sequències ortòlogues anteriors els 10 millors motius de 5-15pb.

Seleccionem el mode clàssic, ja que el altres dos mètodes necessiten un control del què nosaltres no disposem:

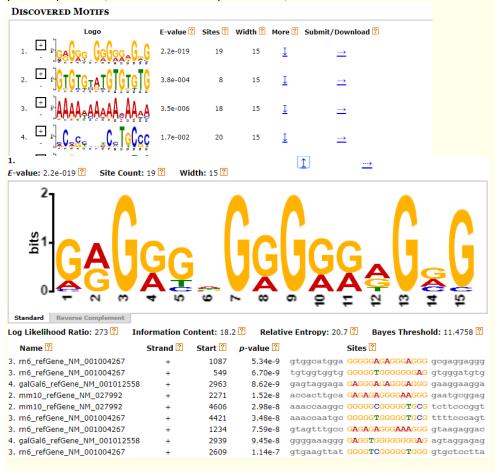
# Select the motif discovery mode ?

#### You provide one set of sequences and MEME discovers motifs enriched in this set Enrichment is measured relative to a (higher order) random model based on frequencies of the letters in your sequences, or relative to the frequencies given in a "Custom background model" that you may provide (see Advanced options). Discriminative mode You provide two sets of sequences and MEME discovers motifs that are enriched in the first (primary) set relative to the second (control) set. In Discriminative mode, we first calculate a position-specific prior from the two sets of sequences. MEME then searches the first set of sequences for motifs using the position-specific prior to inform the search. This approach is based on the simple discriminative prior "D" described in Section 3.5 of Narlikar et al. We modify their approach to search for the "best" initial motif width, and to handle protein sequences using spaced triples. Refer to the psp-gen documentation and to our paper for more details. Differential Enrichment mode You provide two sets of sequences and MEME discovers motifs that are enriched in the first (primary) set relative to the second (control) set. In Differential Enrichment mode, MEME optimizes an objective function based on the hypergeometric distribution to determine the relative enrichment of sites in the primary sequences compared to the control sequences

Seleccionem 10 motius amb una amplada de 5-15 pb i executem.

Data Submission Form	_
Perform motif discovery on DNA, RNA, protein or custom alphabet datasets.	Any Number of Repetitions (anr) ▼
Select the motif discovery mode  Classic mode Discriminative mode Differential Enrichment mode Select the sequence alphabet	Select the number of motifs How many motifs should MEME find? 1
Use sequences with a standard alphabet or specify a custom alphabet.   DNA, RNA or Protein Custom Selectionar archivo Elizabeta alphabet.	Input job details (Optional) Enter your email address.  wellw001@hotmail.com
Input the primary sequences	(Optional) Enter a job description.
Enter sequences in which you want to find motifs.   Type in sequences   [DXX]	PAC2
catgagcastactgccagcagcgctcgcacctgcagcagctctggactgg tgttagaggtgttgggctccagagcagctctgaggccatggcctgtcctc atgetcacccatgctgcatasagcctattccttattcctttcct	What should be used as the background model?  0-order model of sequences ▼ ♥  How wide can motifs be?  Maximum width: 5 ★ ■  How many sites must each motif have?  ■ Maximum sites: ■ ■ ■ Maximum sites: ● ■  Can motif sites be on both strands? (DNA/RNA only)  ■ search given strand only №  Should MEME restrict the search to palindromes? (DNA only)

A continuació mostrem els primers resultats obtinguts (veure <u>annex8</u>). Com es demanen els 10 millors i MEME mostra els 10 primers que troba, sense tenir en compte l'E-value, farem la cerca de 30 i seleccionarem els 10 millors (veure <u>annex8b</u>).



El primer resultat té un E-value significatiu, així que el farem servir per fer la comparació amb la base de dades de Jaspar, mitjançat l'opció TOMTOM.

#### 11. TOMTOM dins de la suite de programes MEME. Exemple amb algun del motius anteriors.

JASPAR és un catàleg de models de predicció pel reconeixement del llocs d'unió a factors de transcripció en regions reguladores. Trobem diferents col·leccions de matrius de pesos classificades per espècies .La llista de motius reconeguts per un determinat factor de transcripció (TF) es representen gràficament amb un logotip de seqüència, de manera que podem avaluar la variabilitat d'aquests motius. Aquests mateixos logotips són els que obtenim en el outputs de MEME.

Desde MEME, la opció *Submit to program* – TOMTOM, permet comparar el motiu/s obtinguts amb múltiples catàlegs per identificar a quina familia de TFs podria pertànyer.

TOMTOM ens enllaça amb JASPAR on se'ns mostren les coincidència obtingudes. Dintre de cada TF de la llista podem veure la matriu de freqüencies numèriques, tant de JASPAR com de TRANSFAC.

#### QUERY MOTIFS Database ? ID ? Alt. ID ? Preview ? Matches ? List ? MA0528.1 (ZNF263), UP00021 1 (Zfp281 primary), MA0516.1 (SP2), UP00022 1 (Zfp740 primary), query\_motifs MA0079.3 (SP1), MA0471.1 (E2F6), MA0470.1 (E2F4), MA0057.1 (MZF1(var.2)), Detailed information of matrix profile MA0528.1 Sequence logo Matrix ID: MA0528.1 Family More than 3 adjacent zinc finger factor CORE Vertebrates Taxon Species

Exercici 2. Anotació computacional del gens.

#### 1. GENEID. Coordenades dels exons del gen de la seqüència anonima.fa.

GENEID és un dels programes pioners de predicció gènica. Identifica els exons codificants d'una seqüència problema *ab initio* (de novo o intrínseca), és a dir, es basa en la construcció de models estadístics a partir de l'estudi d'abundants coleccions d'exons reals per capturar la composició dels senyals i les regions codificants internes sense fer servir informació externa derivada de l'ús de bases de dades d'homologies. GENEID posseeix, a més, un potent algoritme d'acoblament de gens basat en l'us de programació dinàmica. Els programes de predicció *ab initio* inclouen també fitxers de paràmetres per cada grup taxonòmic, basats en la distribució estadística dels senyals i regions codificants dins de cada espècie. Es calculen també el valors òptims de la distribució de nucleòtids al voltant de cada senyal, i s'identifiquen els falsos positius prenent com a referència una àmplia mostra de regions no exòniques (model negatiu de contrast). Executem la cerca per la nostra seqüència problema *anonima.fa* amb format de sortida GFF:

```
## gff-version 2
## date Thu May 7 18:44:05 2020
## source-version: geneid v 1.2 -- geneid@imim.es
# Sequence human - Length = 37571 bps
# Optimal Gene Structure. 2 genes. Score = 31.87
# Gene 1 (Forward). 11 exons. 622 aa. Score = 31.87
human geneid v1.2 First 157 286 9.81 + 0 human_1
human geneid v1.2 Internal 10376 10488 1.45 + 2 human_1
human geneid v1.2 Internal 10376 10488 1.45 + 2 human_1
human geneid v1.2 Internal 12800 12857 0.89 + 0 human_1
human geneid v1.2 Internal 15504 15655 -0.00 + 2 human_1
human geneid v1.2 Internal 15504 15655 -0.00 + 2 human_1
human geneid v1.2 Internal 17255 17406 5.73 + 1 human_1
human geneid v1.2 Internal 17255 17406 5.73 + 1 human_1
human geneid v1.2 Internal 23771 23865 -1.35 + 2 human_1
human geneid v1.2 Internal 25045 25142 2.96 + 0 human_1
human geneid v1.2 Internal 26262 26281 2.17 + 1 human_1
human geneid v1.2 Internal 27296 27427 2.70 + 2 human_1
human geneid v1.2 Internal 28008 28858 6.20 + 2 human_1
human geneid v1.2 First 30518 30529 -2.92 + 0 human_2
human geneid v1.2 First 30518 30529 -2.92 + 0 human_2
human geneid v1.2 Internal 30780 30932 0.68 + 0 human_2
human geneid v1.2 Internal 31931 31994 2.93 + 0 human_2
human geneid v1.2 Internal 31331 31994 2.93 + 0 human_2
human geneid v1.2 Internal 31331 31994 2.93 + 0 human_2
human geneid v1.2 Internal 31331 31994 2.93 + 0 human_2
human geneid v1.2 Internal 30518 30529 -0.40 + 2 human_2
human geneid v1.2 Internal 31331 31994 2.93 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Internal 30518 30580 30892 0.68 + 0 human_2
human geneid v1.2 Interna
```

Obtenim 2 gens, un d'onze exons i 622 aa, i un altre de 4 exons i 141 aa. Les primeres dues columnes numèriques a la dreta del tipus d'exó (first, internal o terminal) ens indiquen les posicions d'inici i final, respectivament. Les següents columnes indiquen la puntuació otorgada per GENEID, el sentit de lectura (+ o -) i la pauta de lectura (1,2 o 3).

De la totalitat de possibles exons identificats, GENEID només fa servir una petita part d'aquests per acoblar el gen o gens més plausibles. El programa compara simultàneament la composició dels codons i les dependències entre aa propers respecte a aquells valors coneguts per determinat organisme ja que, dins d'una proteïna, alguns aa apareixen junts amb més freqüència.

Si canviem el format de sortida a geneid obtenim la proteïna resultant de la traducció d'aquests 2 gens:

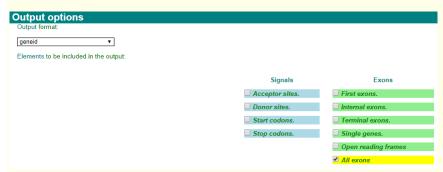
```
# Optimal Gene Structure, 2 genes, Scole - 01...

# Gene 1 (Forward), 11 exons, 622 aa, Score = 31.58

First 157 286 9.81 + 0 1 8.

Internal 10376 10458 1.45 + 2 0 5.
                        157
10376
12800
                                         286
10458
12857
                                                                                                                2.83
2.65
3.09
                                                                                                                                                                     1: 44 human_1
44: 71 human_1
72: 91 human_1
                                                                                                                                                             AA
AA
                                                                 0.89
Internal
                                                                                                                4.65
1.67
3.72
                                                                                                                                               0.00
                                                                                                                                                             AA 91:141 human_1
AA 142:163 human_1
AA 163:224 human_1
Internal
                        15504
                                         15655
                                                                                                                                5.41
                       16764
17225
                                         16828
17406
Internal
                                                                                                3.69
                                                                                                                                               0.00
                                                                                                                                                             AA 224:255 human_1
AA 256:288 human_1
AA 288:295 human_1
Internal
                                                                                                -0.44
                                                                                                                3.68
                                                                                                3.54
6.90
                                                                                                                0.05
                       26262
                                          26281
Internal
Internal
                                          27427
                                                                                                0.45
                                                                                                                                                             AA 295:339 human
>human_1|geneid_v1.2_predicted_protein_1|622_AA
MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY
CMWVQDEPLLQEELANTIAQLVHAVNNSAAQACVWFFSRIKVFLDVLMKEVLCPESQSPN
GVRFHFIDIYLDELSKVGGKELLADONLKFIDPFCKIAAKTKDHTLVOTIARGVFEAIVD
QSPFVPEETMEEQKTKVGDGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERG
RDDCGTFEDTGPLLQFDYKAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQ
LSFAEDISADEDDQILSQGKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRK
KKKKHHLQPENPGPGGAAPSLEQNRGREPFASGLKALKARVAEPGAEATSSTGEESGSEH
PPAVPMHNKRKRPRKKSPRAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLK
RKRKLGVVPVNGSGLSTPAWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLEL
CGLPSQKTASLKKRKKMRVMSNLVEHNGVLESEAGQPQALVRWEHPQASSPQRHSLASMG
LHCLLRGRVGAGGQASGLSSS*
                       30518
30780
                                         30529
30932
                                                              -2.92
0.68
First
Internal
                                                                             + 0 0 + 0 0
                                                                                                1.42
                                                                                                                                                            AA
AA
AA
AA
                                                                                                                                                                     1: 4 human_2
5: 55 human_2
56: 77 human_2
77:141 human_2
 Internal
                                          31994
>human_2|geneid_v1.2_predicted_protein_2|141_AA
MKIKGSSGTCSSLKKQKLRAESDFVKFDTPFLPKPLFFRRAKSSTATHPPGPAVQLNKTP
SSSKKVTFGLNRNMTAEFKKTDKSILVSPTGPSRVAFDPEQKPLHGVLKTPTSSPASSPL
VAKKPLTTTPRRRPRAMDFF*
```

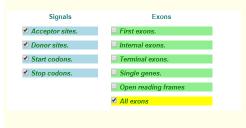
Si seleccionem com a format de sortida geneid i l'opció "All exons" obtenim tots el possibles exons:



Només mostrarem els primers ja que amb una seqüència de més de 37mil bases s'obtenen també milers de possibles exons:

# Sequence human - Length = 37571 bps	
# Exons(x) predicted in sequence human: [0,37570]  Begin 0 0 0.00 + 0 0 0.00 0.00 0.00 0.00 1 X	
Begin 0 0 0.00 - 0 0 0.00 0.00 0.00 1 X	
	LCDAISPRAAAAAFCAVAARADg
	2
	AFVTPSARAPPPPPSVQSRPGRT
	LCDAISPRAAAAAFCAVAARADGGWLLRSARLAAAAPRVAR
	AFVTPSARAPPPPPSVQSRPGRTVAGCSAALGWLQRHRGLR
	AFVTPSARAPPPPPSVQSRPGRTVAGCSAALGWLQRHRGLR
	AFVTPSARAPPPPPSVQSRPGRTVAGCSAALGWLQRHRGLR
Terminal 2 18 -5.78 + 2 0 -0.43 0.00 -1.31 0.00 6 ccAF	
	LCDAISPRAAAAAFCAVAARADGGWLLRSARLAAAAPRVAR
First 20 24 -2.76 - 0 2 -4.78 8.52 0.00 0.00 2 Mgc	
	RSVPDALLAGRQPLGKLDLGRLHGGGHRARWSIPGRATRGA
Internal 20 246 -11.43 - 20 -4.78 0.38 -9.48 0.00 76 ctSS	SPLGPGCPSRWTPAAGQIGSRPAAWRGPSRPLEHPRPRNPR
Internal 20 201 -10.78 - 0 2 -4.78 -0.90 -5.91 0.00 61 PLGF	KLDLGRLHGGGHRARWSIPGRATRGAAAASRALRSSQPPSA
Internal 20 201 -10.33 - 2 0 -4.78 -0.90 -4.80 0.00 61 ccAG	GQIGSRPAAWRGPSRPLEHPRPRNPRCRCSQPSAAEQPATV
Internal 20 107 -8.33 - 1 0 -4.78 -0.52 -0.36 0.00 30 cQPS	SAAEQPATVRPGRDCTEGGGGGARADG
Internal 20 107 -9.83 - 2 2 -4.78 -0.52 -4.11 0.00 30 ccSF	RALRSSQPPSARAATAQKAAAAARGLMgc
Internal 20 103 -10.74 - 0 0 -4.78 -4.44 -0.52 0.00 28 PSAF	AEQPATVRPGRDCTEGGGGGARADG
Internal 20 103 -12.10 - 1 2 -4.78 -4.44 -3.92 0.00 29 CRAI	LRSSQPPSARAATAQKAAAAARGLMgc
Internal 20 51 -8.69 - 0 2 -4.78 -1.39 0.05 0.00 11 KAAA	AAARGLMgc
Internal 20 51 -8.37 - 20 -4.78 -1.39 0.83 0.00 11 aaGG	GGGGARADG
Terminal 24 344 -2.71 - 0 0 0.00 -0.40 6.32 0.00 107 PQPF	RPPARHVARLTAAVRPPVSLCVFTLMYWRSFFTARSRMPFS
Terminal 24 338 -4.75 - 0 0 0.00 -4.25 7.01 0.00 105 PRPE	PARHVARLTAAVRPPVSLCVFTLMYWRSFFTARSRMPFSLD
Terminal 24 246 -4.14 - 1 0 0.00 0.38 1.58 0.00 75 cFFT	TARSRMPFSLDASRWANWISAGCMAGAIAPAGASPAAQPAV
	ANWISAGCMAGAIAPAGASPAAQPAVPLQPAERCGAASHRP

Podem estudiar el patró de nucleòtids si seleccionem visualitzar els senyals que delimiten el inici i final d'aquests exons (donada la seva extensió, també es mostraran només els primers):



Sequence human - Length = 37571 bps

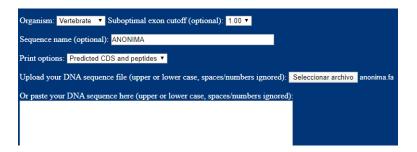
```
# Starts(+) predicted in sequence human: [0,37570]
  Start
              140
                       142
                              3.00
                                                  TTGCGCGGCCGGGGATGCTC
              157
                        159
                              8.07
                                                  CTCCAGCGGGCGCGATGGCC
  Start
  Start
              169
                        171
                              3.77
                                                  CGATGGCCCCCGCCATGCAG
                              4.97
              318
                        320
                                                  GTCAGCCGCGCCACATGGCG
  Start.
  Start
              369
                        371
                              4.31
              496
                        498
                              -0.81
                                                  GGGTTCCGTTACTTATGAAA
   Start
   Start
              537
                        539
                                                  GAGAAAAGACCCACATGGGT
              757
                        759
                             -2.32
  Start
```

És recomanable fer servir diferents programes de predicció génica per estudiar quines són les prediccions en comú. També és interessant comparar aquestes prediccions amb bases de dades de proteïnes per enriquir aquestes prediccions.

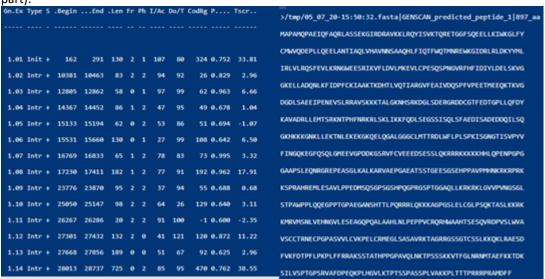
#### 2. GENSCAN. Predicció de gens en la seqüència anonima.fa

GENSCAN és un programa que prediu la localització de gens i les estructures exó/intró en seqüències gèniques de diferents organismes.

Deixarem com a "suboptimal exon cuttoff" el que ve per defecte, ja que de moment ens interessen el exons més plausibles. Seleccionem "Vertebrate". Els programes de predicció gènica treballen amb bases de dades d'exons pròpies de cada grup taxonòmic, per capturar amb precisió la distribució estadística de senyals i regions codficants, i fer les parametrizatbles.



La quantitat de possibles exons que obtenim aquí és menor. Observem una llista resultant d'aquests exons on també s'indica el tipus d'exó, l'inici, el final, la longitud, score, ORF,..i a continuació el pèptid predit i la possible regió CDS (només mostrem una part):



#### 3. FEGENESH. Predicció de l'estructura génica basada en HMM (multiples genes, both chains).

FGENESH és un software de predicció gènica *ab initio* (de novo o intrínseca) basat en HMM. Introduim de nou la nostra seqüència *anonima.fa* 

Local file name:	
Seleccionar archivo	anonima.fa
Select organism specif	ic gene-finding parameters :
Human ( Homo sapiens )	▼
search Reset	

Obtenim (veure <u>annex9</u>) dins de la nostra seqüència problema, un possible gen i 16 possibles exons. L'aplicació ens retorna, a més de la llista d'exons (amb especificacions similars a les de les altres aplicacions), la seqüència del mRNA (perquè és una opció marcada per defecte) i de la proteïna resultant del gen predit.

```
FGENESH 2.6 Prediction of potential genes in Homo_sapiens genomic DNA Time : Thu May 7 16:26:14 2020
Seq name: human
Length of sequence: 37571
Number of predicted genes 1: in +chain 1, in -chain 0.
Number of predicted exons 16: in +chain 16, in -chain 0.
                                                                         1, Score:115.993872
Positions of predicted genes and exons: Variant
                                                                      ORF
  G Str
           Feature
                                         End
                        Start
                                                 Score
                                                                                        Len
           2 CDSi
                         10376 -
                                        10458
                                                   7.43
                                                               10378 -
                                                                              10458
                                                                                          81
                                                                              12856
           3 CDSi
                         12800 -
                                                               12800 -
                         14362
                                        14447
                                                               14364 -
                                                                                           84
           4 CDSi
                                                   3.34
                                                                              14447
           5 CDSi
6 CDSi
                                        15189
15655
                                                              15128 -
15527 -
                         15128 -
                                                                              15187
                                                                              15655
                                                                                         129
           7 CDSi
                         16764 -
                                        16828
                                                    6.62
                                                               16764 -
                                                                              16826
                                                                                           63
                                                  2.10
           9 CDSi
                                        23865
                                                               23773 -
                                                                              23865
                                                                                          93
                                                               25045
         11 CDSi
                        26262
                                        26281
                                                               26263
                                                                              26280
```

#### Alguns exons i la possible proteïna:

Percent Identity Matrix - created by Clustal2.1

```
>FGENESH:[exon] Gene: 1 Exon: 14 Pos: 30780 - 30932 153 bp., chain +
GGAAGCAGTGGGACTTGCAGTTCCCTGAAGAAGCAGAAGCTGAGGGCAGAGAGCGACTTT
>FGENESH: [exon] Gene: 1 Exon: 15 Pos: 31931 - 31994 6
CTAAACAAGACACCATCCAGCTCCAAGAAAGTCACCTTTGGGCTGAACAGAAACATGACT
                                                                                        64 bp., chain +
FGENESH:[exon] Gene: 1 Exon: 16 Pos: 33682 | - 33875 19
AATTCAAGAAGACAGACAAGAGTATCTTGGTCAGTCCCAGGGCCCTTCTCGAGTGGCCT
TCGACCCTGAACAGAAGCCCCTCCACGGGGTGCTGAAGACCCCCACCACCACCTCACCTGCCA
GCTCACCCCTGGTGGCCAAGAAGCCCCTGACCACCACACCAAGGAGAAGGCCCAGGGCTA
TGGATTTCTTCTGA
                      16 exon (s)
                                             157
                                                        33875
>FGENESH:
MAPAMOPAEIOFAORLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY
CMWYODE PLIQEELANTIAQLYHAVNNSAAQHLFIQFFWQTMNRBWKGIRLRLDKYYML
IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG
GKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVDQSPFVPEETMEEQKTKVG
dgdlsaeeipenevslrravskkktalgknhsrkdglsdergrddcgtfedtgpllofdy
KAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQLSFAEDISADEDDQILSQ
GKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRKKKKHHLQPENPGPGGAA
PSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEHPPAVPMHNKRKRPRKKSP
RAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLKRKRKLGVVPVNNGSGLSTP
AWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLELCGLPSQKTASLKKRKKMR
VMSNLVEHNGVLESEAGQPQALGSSGTCSSLKKQKLRAESDFVKFDTPFLPKPLFFRRAK
SSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDKSILVSPTGPSRVAFDPEQK
PLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF
```

# 4. Alineament global amb CLUSTAL de les proteïnes obtingudes anteriormente en GENEID, GENSCAN i FGENESH.

Realitzem l'alineament global dels tres pèptids obtinguts en els apartats 1, 2 i 3 amb CLUSTAL. En primer lloc, en el cas de GENEID prenem només el gen 1 (veure seqüències alineades en <u>annex10</u>). Obtenim uns percentatges alts d'identitat, que és màxima entre els resultats de FGENESH i GENSCAN

La diferència més notable la trobem a la proteïna obtinguda per GENEID, observem d'entrada que el número d'aa és diferent i, si observem l'alineament obtingut a CLUSTAL, veiem que és principalment a l'extrem terminal on es perd aquesta identitat amb les altres dues següències.

Això és degut a que, el que GENSCAN i FGENESH identifiquen com un únic gen, en GENEID resulten 2, ja que reconeix un codó de parada a l'exó terminal del primer gen. Cada programa implementa els seus propis algoritmes i estableix uns llindars (*cutoff o threshold*) de puntuació, de manera que els resultats no sempre coincideixen.

Canviem a CLUSTAL la seqüència de la proteïna de GENEID: li afegim el pèptid del gen (veure <u>annex11</u>). Observem que la identitat augmenta en l'extrem terminal:

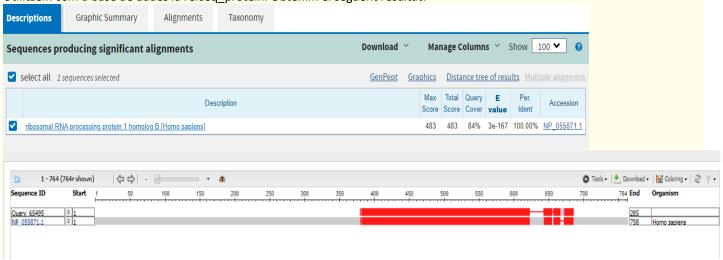
```
human_1|geneid_v1.2_predicted_protein_1|622_AA
                                                                  KMRVMSNLVEHNGVLESEAGOPOALVRWEHPOA-----SSPORHSL-ASMG
                                                                                                                                    600
                                                                   KMRVMSNLVEHNGVLESEAGQPQAL-----
FGENESH:
                                                                                                                                    622
/tmp/05_08_20-11:44:37.fasta|GENSCAN_predicted_peptide_1|897_aa
                                                                   KMRVMSNLVEHNGVLESEAGQPQALAAHLNLPEPPVCRQRHWAAHTSESQVRDPVSLWVA
human_1|geneid_v1.2_predicted_protein_1|622_AA
                                                                   LHCLLRGRV-----GAGGQASGLSSSMKIKGSSGTCSSLKKQKLRAESD
                                                                                                -----GSSGTCSSLKKQKLRAESD
                                                                                                                                    641
/tmp/05_08_20-11:44:37.fasta|GENSCAN_predicted_peptide_1|897_aa
                                                                  VSCCTRNECPGPASVVLCVKPELCRMEGLSASAVRKTAGRRGSSGTCSSLKKQKLRAESD
                                                                                                                                    780
human_1|geneid_v1.2_predicted_protein_1|622_AA
                                                                   FVKFDTPFLPKPLFFRRAKSSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDK
                                                                                                                                    794
FGENESH:
                                                                   FVKFDTPFLPKPLFFRRAKSSTATHPPGPAVOLNKTPSSSKKVTFGLNRNMTAEFKKTDK
                                                                                                                                    701
/tmp/05_08_20-11:44:37.fasta|GENSCAN_predicted_peptide_1|897_aa
                                                                   FVKFDTPFLPKPLFFRRAKSSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDK
                                                                                                                                    840
                                                                   SILVSPTGPSRVAFDPEOKPLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF* 761
human_1|geneid_v1.2_predicted_protein_1|622_AA
                                                                   SILVSPTGPSRVAFDPEOKPLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF- 758
/tmp/05_08_20-11:44:37.fasta|GENSCAN_predicted_peptide_1|897_aa
                                                                   SILVSPTGPSRVAFDPEQKPLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF- 897
```

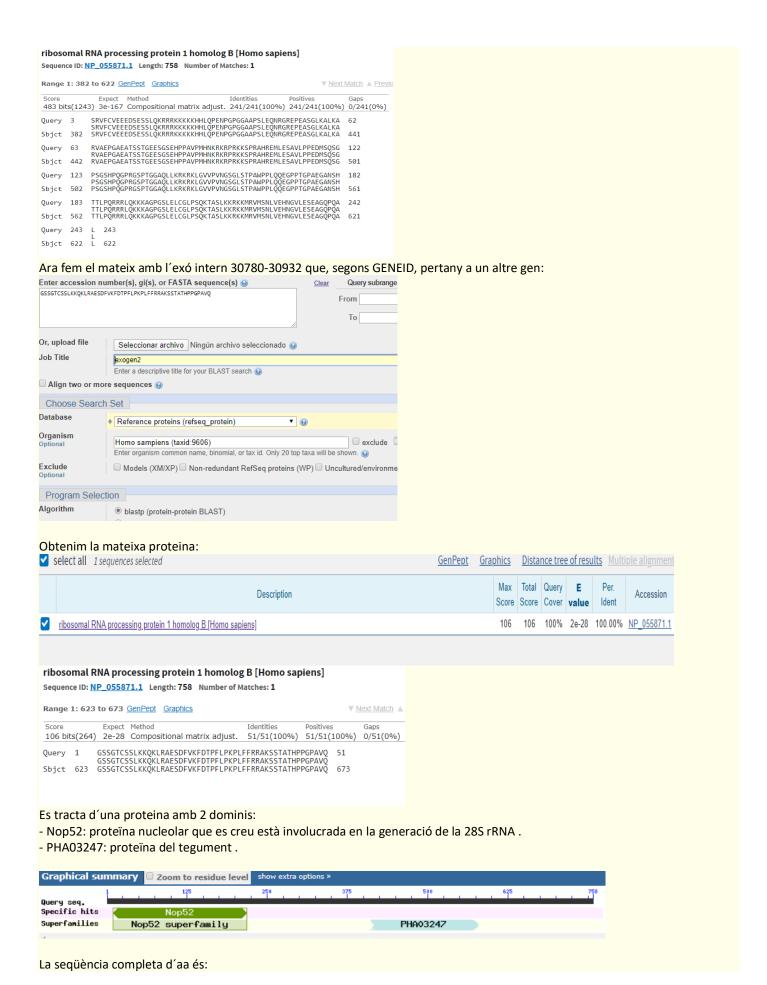
#### 5. Coordenades dels exons.

	GENEID		GENSCAN	FGENESH	Exó
Gen 1	inicial	157-286**	162-291***	157-286***	inicial
	intern	10376-10458	10381-10463	10376-10458	intern
	intern	12800-12857	12805-12862	12800-12857	intern
	intern		14367-14452	14362-14447	intern
	intern		15133-15194	15128-15189	intern
	intern	15504-15655	15531-15660	15526-15655	intern
	intern	16764-16828	16769-16833	16764-16828	intern
	intern	17225-17406*	17230-17411**	17225-17406*	intern
	intern	23771-23865	23776-23870	23771-23865	intern
	intern	25045-25142	25050-25147	25045-25142	intern
	intern	26262-26281	26267-26286	26262-26281	intern
	intern	27296-27427*	27301-27432*	27296-27427*	intern
	intern		27668-27856		intern
	terminal	28008-28858**	28013-28737***	28008-28732***	intern
			30241-30385		intern
Gen 2	inicial	30518-30529	30594-30676		intern
	intern	30780-30932	30785-30937*	30780-30932*	intern
	intern	31931-31994	31936-31999*	31931-31994*	intern
	terminal	33682-33875	33687-33880*	33682-33875	terminal

Observem a la taula que hi han moltes coincidències. Alguns exons han estat simultàneament detectats pels 3 programes. A la taula s'han marcat també els exons amb un *score* més alt (\*\*\*>\*\*>\*) i també hi ha coincidències en aquesta puntuació. Amb BLASTP podem reforçar aquestes prediccions obtingudes amb estratègies *de novo*, fent una validació per homologia amb proteines conegudes. Prenem com a exemple l'exó terminal del Gen1 que obtingut amb GENEID que, a més, té una alta puntuació i coincideix bastant amb el altres dos resultats.

Utilitzem com a base de dades la refseq\_protein. Obtenim el següent resultat:





#### Translation (758 aa):

MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFYCMWVQDEPLL
QEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYMLIRLVLRQSFEVLKRNGWEES
RIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVGGKELLADQNLKFIDPFCKIAAKTKDHTLVQ
TIARGVFEAIVDQSPFVPEETMEEQKTKVGDGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDE
RGRDDCGTFEDTGPLLQFDYKAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQLSFAEDIS
ADEDDQILSQGKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRKKKKKHHLQPENPGPGGAA
PSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEHPPAVPMHNKRKRPRKKSPRAHREMLESA
VLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLKRKRKLGVVPVNGSGLSTPAMPPLQQEGPPTGPAEGANS
HTTLPQRRRLQKKKAGPGSLELGGLPSQKTASLKKRKKMRVMSNLVEHNGVLESEAGQPQALGSSGTCSS
LKKQKLRAESDFVKFDTPFLPKPLFFRRAKSSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTD
KSILVSPTGPSRVAFDPEQKPLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF

En blau es representen els exons i en vermell els aa implicats en l'splicing. Comprobem que, efectivament, que els dos exons hi són.

## 6. Localització en el genoma (BLAT).

## RefSeq Gene RRP1B

RefSeq: NM\_015056.3 Status: Validated Description: ribosomal RNA processing 1B

Molecule type: mRNA Source: BestRefSeq Biotype: protein\_coding

Biotype: protein\_coding Synonyms: KIAA0179,Nnp1,NNP1L,PPP1R136,RRP1

OMIM: 610654 Protein: NP 055871.1 HGNC: 23818 Entrez Gene: 23076 GeneCards: RRP1B AceView: RRP1B

#### mRNA/Genomic Alignments (NM\_015056.3)

BROWSER   SIZ					 	TOTAL
browser   50	 	 	43696079	NM 015056.3	 	

View details of parts of alignment within browser window.

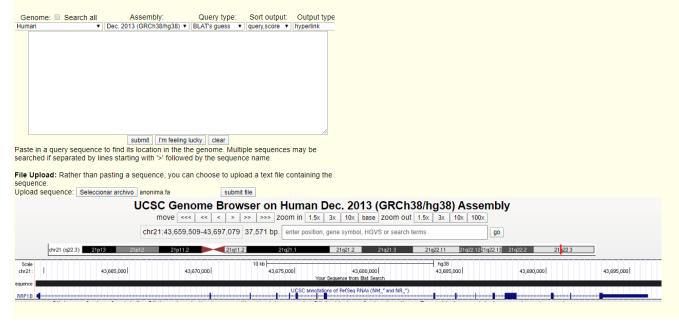
Position: chr21:43659560-43696079

Band: 21q22.3 Genomic Size: 36520 Strand: +

Gene Symbol: RRP1B CDS Start: complete CDS End: complete

Un cop tenim la seqüència localitzada, afegim anonima.fa:

#### **BLAT Search Genome**



## **BLAT Search Results**

ACTIONS	QUERY	SCORE	START	END	QSIZE	IDENTITY	CHROM	STRANI	START	END	SPAN
browser details	human	37571	1	37571	37571	100.0%	chr21	+	43659509	43697079	37571
browser details	human	886	18232	20611	37571	88.9%	chr20	+	21734186	22174431	440246
browser details	human	601	18696	19955	37571	87.4%	chr15	- 4	42655108	42656320	1213
browser details	human	595	18635	19617	37571	88.1%	chr3	+	75534740	75535779	1040
browser details	human	586	18556	19964	37571	84.9%	chr10	+ (	52391808	62392831	1024
browser details	human	566	18554	20161	37571	85.5%	chr2	-	39200465	39201425	961
browser details	human	565	18875	20117	37571	87.7%	chr3	+ :	15744540	15745728	1189
browser details	human	554	18557	20147	37571	84.9%	chr10	+	59721602	59722542	941
browser details	human	536	18819	20165	37571	85.7%	chr2	+	73585562	73586788	1227
browser details	human	535	18953	20168	37571	85.6%	chr6	+ (	53194136	63195017	882
browser details	human	531	18554	19659	37571	84.5%	chr16_KZ559113v1_fix	+	123422	124250	829
browser details	human	519	18555	19631	37571	86.4%	chr3	+ 14	41132858	141133675	818
browser details	human	519	18234	19073	37571	86.3%	chr1	+ 2	32826713	232827646	934
browser details	human	497	18235	19145	37571	93.8%	chr21	- 4	44588159	45275677	687519

Les coordenades del gen RRP1B són chr21: 43659560-43696079(+), mentre que la localització de anonima.fa és chr21:43659509-43697079 (+) en la versió hg38 del genoma humà (a la imatge la veiem com una linea densa i negra).

## 7. Conversió de les prediccions a format GFF. Crear un custom track.

Calculem manualment les posicions:

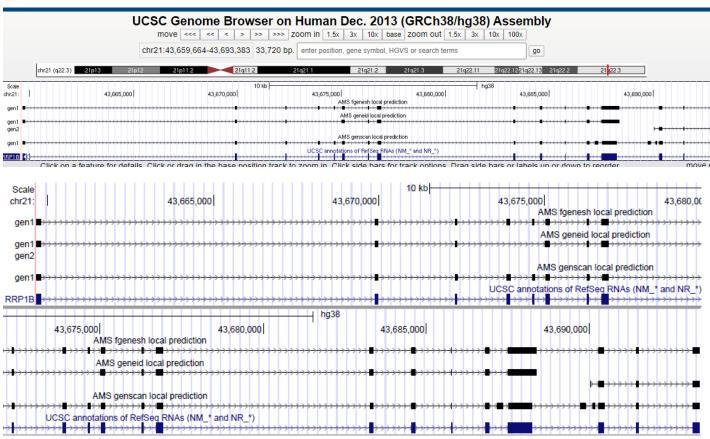
```
browser position chr21: 43659509-43697079
browser hide all
track name=Genscan description="AMS genscan local prediction" visibility=2
chr21 Genscan first 43659670 43659799 33.81 + chr21 Genscan internal 43669889 43669971 2.96 + chr21 Genscan internal 43672313 43672370 6.66 +
                                                                                            aen1
                                                                               0
                                                                                            aen1
          Genscan internal 43673875 43673960 1.04
Genscan internal 43674641 43674702 1
chr21
                                                                                           gen1
chr21
                                                                                            gen1
          Genscan internal 43675039 43675168 6.5
chr21
                                                                                           gen1
          Genscan internal 43676277 43676341 3.32
Genscan internal 43676738 43676919 17.9
                                                                                           gen1
chr21
                                                                                            gen1
chr21
chr21
          Genscan internal 43683284 43683378 0.68
                                                                                           gen1
          Genscan internal 43684558 43684655 3.
Genscan internal 43685775 43685794 1
                                                                                           gen1
gen1
chr21
                      internal 43684558 43684655 3.11
chr21
          Genscan internal 43686809 43686940 11.22
Genscan internal 43687176 43687364 2.96
                                                                                           gen1
chr21
chr21
                                                                                            gen1
          Genscan internal 43687521 43688245 38.55
chr21
          Genscan internal 43689749 43689893 1.26
Genscan internal 43690102 43690184 1
                                                                                           gen1
chr21
chr21
                                                                                            aen1
chr21
          Genscan internal 43690293 43690445 13.67
                                                                                           gen1
       Genscan internal 43691444 43691507 10.39
Genscan terminal 43693195 43693388 9.38
chr21
chr21
                                                                                            gen1
browser position chr21: 43659509-43697079
browser hide all
track name=Geneid description="AMS geneid local prediction" visibility=2
chr21 Geneid first 43659665 43659794 9.81 + 0
          Geneid internal 43669884 43669966 1.45
Geneid internal 43672308 43672365 1
                                                                                            gen1
chr21
chr21
                                                                                            gen1
          Geneid internal 43675012 43675163 1
chr21
                                                                                           gen1
          Geneid internal 43676272 43676336 1.03
Geneid internal 43676733 43676914 5.73
                                                                               0
1
chr21
                                                                                           gen1
chr21
                                                                                            gen1
          Geneid internal 43683279 43683373 1
Geneid internal 43684553 43684650 2.
                                                                               2
chr21
                                                                                           gen1
                      internal 43684553 43684650 2.96
chr21
          Geneid internal 43685770 43685789 2.17
                                                                                           gen1
chr21
                                                                              2 2 0 0 0
          Geneid internal 43686804 43686935 2.7
Geneid terminal 43687516 43688366 6.2
                                                                                           gen1
chr21
chr21
                                                                                            gen1
          Geneid first 43690026 43690037 1
Geneid internal 43690288 43690440 1
chr21
                                                                                           gen2
chr21
                                                                                            aen2
          Geneid
chr21
                      internal 43691439 43691502 2.93
                                                                                            aen2
           Geneid terminal 43693190 43693383 1
chr21
                                                                                            gen2
browser position chr21: 43659509-43697079
browser hide all
track name=fgenesh description="AMS fgenesh local prediction" visibility=2
                                 43659665 43659794 28.3 + 0
                                                                                            gen1
chr21 fgenesh first
         fgenesh internal 43669884 43669966 7.43 + fgenesh internal 43672308 43672365 6.33 +
                      internal 43669884 43669966 7.43
chr21
                                                                                            gen1
          fgenesh internal 43673870 43673955 3.34 fgenesh internal 43674636 43674697 2.4
chr21
                                                                                           aen1
                                                                                            gen1
chr21
chr21
          fgenesh internal 43675034 43675163 6.39
                                                                                           gen1
          fgenesh internal 43676272 43676336 6.62 + fgenesh internal 43676733 43676914 12.24 +
                                                                                            gen1
chr21
chr21
                                                                                            gen1
          fgenesh internal 43683279 43683373 2.1 fgenesh internal 43684553 43684650 1
chr21
                                                                                            gen1
chr21
                                                                                            gen1
```

```
chr21
                   internal 43685770 43685789 1
         faenesh
                                                                              gen1
                   internal 43686804 43686935 8.29
chr21
         fgenesh
                                                                              gen1
chr21
         fgenesh
                   internal 43687516 43688366
                                                33.29
                                                                              gen1
                   internal 43690288 43690440
                                                9.89
                                                                    0
chr21
         fgenesh
                                                                              gen1
                   internal 43691439 43691502
                                                13.04
chr21
                                                                    0
                                                                              gen1
         fgenesh
                   terminal 43693190 43693383 1.9
chr21
         fgenesh
                                                                              gen1
```

Un cop tenim les nostres dades en format GFF creem les nostres custom tracks a genomeBrowser d'UCSC:

Manage	Manage Custom Tracks										
genome:											
Name	Description	Туре	Doc	Items	Pos	delete	view in	Genome Browser ▼ go			
<u>fgenesh</u>	AMS fgenesh local prediction	gff		1	chr21:			add custom tracks			
Geneid	AMS geneid local prediction	gff		2	chr21:						
Genscan	AMS genscan local prediction	gff		1	chr21:						

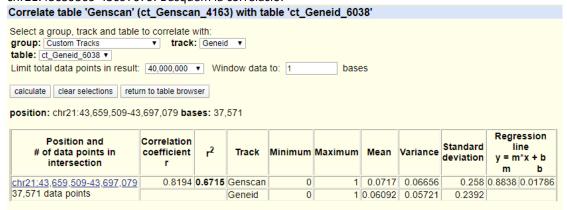
I s i les visualitzem quedarien així:



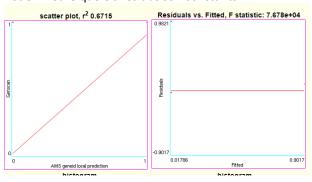
## 8. Correlació entre les prediccions amb Table Browser.

# a. GENEID-GENSCAN

Introduim les dades a *TableBrowser* de genomeBrowser d'UCSC. La regió genòmica que delimita *anonima.fa* és: chr21:43659509-43697079. Busquem la correlació:



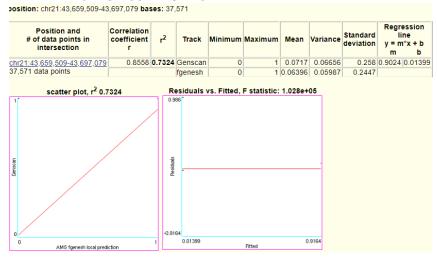
#### Podem veure que els residus són constants :



#### b. GENEID-FGENESH



## c. GENSCAN-FGENESH

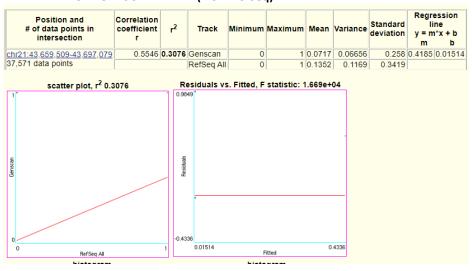


## GENEID-RRP1B (NCBI RefSeq)

#### **Table Browser** Use this program to retrieve the data associated with a track in text format, to calculate intersections be Using the Table Browser for a description of the controls in this form, and the User's Guide for general in MySQL server. To examine the biological function of your set through annotation enrichments, send the with these data. All tables can be downloaded in their entirety from the Sequence and Annotation Down clade: Mammal ▼ genome: Human ▼ assembly: Dec. 2013 (GRCh38/hg38) ▼ group: Custom Tracks ▼ track: Geneid ▼ manage custom tracks track hubs table: ct\_Geneid\_6038 ▼ describe table schema region: O genome O position chr21:43,659,509-43,697,079 lookup define regions identifiers (names/accessions): paste list upload list filter: create intersection: create correlation: calculate | clear | (with: RefSeq All) ▼ Send output to □ Galaxy □ GREAT output format: all fields from selected table (leave blank to keep output in browser) output file: file type returned: plain text gzip compressed

Correlate table 'Geneid' (c	t_Geneid_6	038) w	ith table '	ncbiRefS	eq'					
Select a group, track and table group: Genes and Gene Prediction table: RefSeq All (ncbiRefSeq) Limit total data points in result calculate clear selections return position: chr21:43,659,509-43	track 40,000,000  rn to table brown	NCBII   Wir  wire	ndow data t	0: 1	bases	;				
Position and Correlation # of data points in intersection r Track Minimum Maximum Mean Variance Standard deviation with the conficient of										
	r	•	Huck	William	Waxiiiiuiii	Weali	variance	deviation	,	
	r	•		0		0.06092			,	

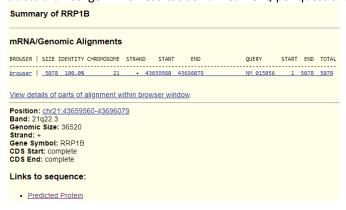
e. GENSCAN-RRP1B (NCBI RefSeq)



## f. FGENESH-RRP1B

Correlate table 'fgenesh' (ct_fgenesh_9515) with table 'ncbiRefSeq'											
Select a group, track and table to correlate with:  group: [Genes and Gene Predictions v track: NCBI RefSeq v table: RefSeq All (ncbiRefSeq) v Limit total data points in result: 40,000,000 v Window data to: 1 bases  calculate   clear selections   return to table browser    position: chr21:43,659,509-43,697,079 bases: 37,571											
Position and Correlation # of data points in intersection r Track Minimum Maximum Mean Variance Standard deviation y = m*x + b m b											
chr21:43,659,509-43,697,079	0.6211	0.3858	fgenesh	0	1	0.06396	0.05987	0.2447	0.4445 0.003878		
37,571 data points			RefSeq All	0	1	0.1352	0.1169	0.3419			

9. Alineament múltiple global de les 3 proteïnes amb RRP1B (CLUSTAL). Quin programa de predicció és millor? Introduim ara a CLUSTAL les 3 prediccions obtingudes i la seqüencia d'aa de RRP1B que obtenim del navegador Genome Browser. La proteïna obtinguda per GENEID serà la resultant de sumar el pèptid del gen 1 i el del gen 2, ja que ara sabem que es tracta d'un sol gen. D'el resultat de l'alineament, per qüestions d'espai, només mostrarem les regions on hi divergència.



Observem a la matriu d'identitat que les proteïnes de FGENESH i GENSCAN tenen un 100% d'identitat amb RRP1B. En canvi, amb GENEID un 99.3%, que és un percentatge també molt alt.

Percent Identity Matrix - created by Clustal2.1

```
1: human_1|geneid_v1.2_predicted_protein_1|622_AA
                                                                   100.00
                                                                            99.30
                                                                                    99.30
2: FGENESH
                                                                    99.30 100.00
                                                                                   100.00
                                                                                           100.00
                                                                    99.30
                                                                                           100.00
3: NP_055871
                                                                          100.00
                                                                                  100.00
4: /tmp/05_08_20-11_44_37.fasta|GENSCAN_predicted_peptide_1|897_aa
                                                                                   100.00
                                                                                           100.00
                                                                    94.35
                                                                           100.00
```

#### Observem ara on són les diferencies entre GENEID i RRP1B:

human_1 geneid_v1.2_predicted_protein_1 622_AA	CMWVQDEPLLQEELANTIAQLVHAVNNSAAQAC	93
FGENESH:	CMWVQDEPLLQEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYML	120
VP_055871	CMWVQDEPLLQEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYML	120
/tmp/05_08_20-11:44:37.fasta GENSCAN_predicted_peptide_1 897_aa	CMWVQDEPLLQEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYML	120
	***************************************	
human_1 geneid_v1.2_predicted_protein_1 622_AA	VWFFSRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG	138
FGENESH:	IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG	180
VP_055871	IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG	180
/tmp/05_08_20-11:44:37.fasta GENSCAN_predicted_peptide_1 897_aa	IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG	180
	* ***************************	

Sembla ser que a GENEID i ha omisió d'un exó o regió primer. A continuació observem, a la part final de la proteïna, que GENEID té un parell de regions extres també.

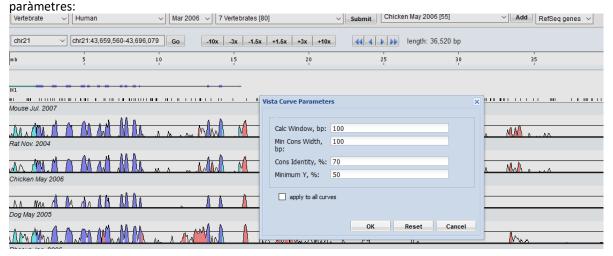
human_1 geneid_v1.2_predicted_protein_1 622_AA	KMRVMSNLVEHNGVLESEAGQPQALVRWEHPQASSPQRHSL-ASMG	600
FGENESH:	KMRVMSNLVEHNGVLESEAGQPQAL-	622
NP_055871	KMRVMSNLVEHNGVLESEAGQPQAL-	622
/tmp/05_08_20-11:44:37.fasta GENSCAN_predicted_peptide_1 897_aa	KMRVMSNLVEHNGVLESEAGQPQALAAHLNLPEPPVCRQRHWAAHTSESQVRDPVSLWVA	720
<pre>human_1 geneid_v1.2_predicted_protein_1 622_AA FGENESH: NP_055871 /tmp/05_88_20-11:44:37.fasta GENSCAN_predicted_peptide_1 897_aa</pre>	LHCLLRGRVGAGGQASGLSSSMKIKGSSGTCSSLKKQKLRAESDGSSGTCSSLKKQKLRAESDGSSGTCSSLKKQKLRAESD VSCCTRNECPGPASVVLCVKPELCRMEGLSASAVRKTAGRRGSSGTCSSLKKQKLRAESD	644 641 641 780

Com a conclusió podem dir que el que ha fet la millor predicció en aquest cas ha estat FGENESH, tant pels resultats de la matriu d'identitat, com pel valor de la correlació amb RRP1B.

## 10. VISTA: grau de conservació dels exons de RRP1B.

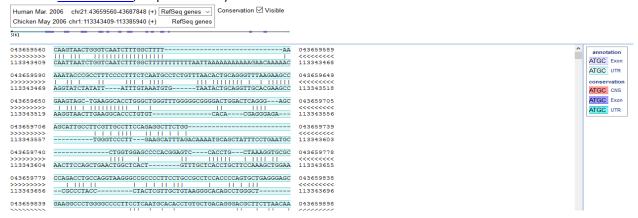
VISTA ens proporciona un alineament per homologia, reconstruint la estructura exònica d'un gen a partir de l'identificació de proteïnes homòlogues conservades en altres espècies. Això ens resultarà útil per guiar la predicció *ab initio*, identificant primer el conjunt de proteïnes conegudes en altres espècies que estan conservades. Així després podem informar a GENEID, GENSCAN o FGENESH sobre l'existència d'homologia amb proteïnes conegudes. Per exemple, podem millorar la predicció a GENEID augmentant la puntuació de aquells exons identificats de novo que presenten solapament amb les regions conservades en tots dos genomes. També ens serveix per reforçar les prediccions obtingudes per les estratègies *de novo*.

Els gràfics representen el percentatge de conservació entre seqüències alineades a una determinada coordenada de la seqüència base. La pista d'anotació gènica es mostra per sobre de les corbes de conservació, on les caixes de color blau fosc i clar representen exons i UTRs respectivament. Les regions d'alta conservació es coloreen segons l'anotació com a exons (blau fosc), UTR (blau clar) o sense codificació (rosa). Les regions es classifiquen en "conservades" mitjançant l'anàlisi de puntuacions de cada pb en l'interval genòmic, és a dir, "Amplada mínima conservada" (valor predeterminat 100 bp) i "Identitat de conservació" (valor predeterminat 70%). Es considera conservada una regió si la conservació sobre aquesta regió és superior o igual a la "Identitat de conservació" i té la longitud mínima de "Amplada mínima conservada". Podem configurar tots aquests



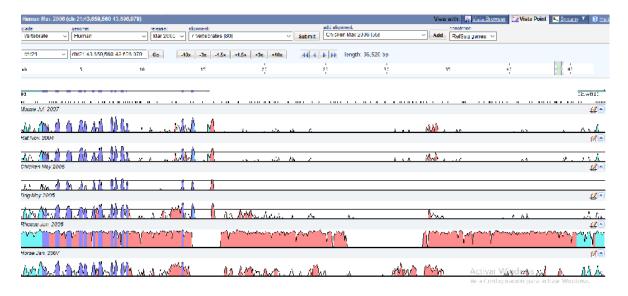
Seleccionem la versió del 2006 perquè conté més informació i, RefSeq genes a la llista d'anotacions. El programa ens permet descarregar un pdf amb la llista de tots el SNPs (veure annex13).

VISTA ens permet també fer alineaments entre espècies. Per exemple, amb pollastre (veure un altre alineament amb ratolí i *Rhesus* a annex 14 i 15, respectivament).



Cal dir, que no es poden detectar elements funcionals curts com a estadísticament significatius en comparacions d'espècies molt properes. Un exemple extrem: ja que el genoma humà i el ximpanzé són un 98,7% idèntics fins i tot a les regions neutres, la gran majoria dels exons són massa breus per destacar com a estadísticament significatius. En general, la potència estadística per detectar elements funcionals de restricció curta augmenta a mesura que augmenta la divergència neutra total de l'espècie comparada.

En general, podem observar que les regions exòniques del gen RRP1B estan molt conservades a totes les espècies (veure annex16)



## Annex 1a. Seqüències CDS.

#### Humà (variant 1 i 2, respectivament):

>hg38 refGene NM 018374 range=chr7:12214811-12231975 5'pad=0 3'pad=0 strand=+ repeatMasking=none ATGGGAAAGTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGC TTATGATGGAGTCACATCTGAAAACATGAGGAATGGACTGGTTAATAGTG AAGTCCATAATGAAGATGGAAGAAATGGAGATGTCTCTCAGTTTCCATAT GTGGAATTTACAGGAAGAGATAGTGTCACCTGCCCTACTTGTCAGGGAAC AGGAAGAATTCCTAGGGGGCAAGAAAACCAACTGGTGGCATTGATTCCAT ATAGTGATCAGAGATTAAGGCCAAGAAGAACAAAGCTGTATGTGATGGCT TCTGTGTTTGTCTGTCTACTCCTTTCTGGATTGGCTGTGTTTTTCCTTTT CCCTCGCTCTATCGACGTGAAATACATTGGTGTAAAATCAGCCTATGTCA GTTATGATGTTCAGAAGCGTACAATTTATTTAAATATCACAAACACACTA AATATAACAAACAATAACTATTACTCTGTCGAAGTTGAAAACATCACTGC CCAAGTTCAATTTTCAAAAACAGTTATTGGAAAGGCACGCTTAAACAACA TAACCATTATTGGTCCACTTGATATGAAACAAATTGATTACACAGTACCT ACCGTTATAGCAGAGGAAATGAGTTATATGTATGATTTCTGTACTCTGAT ATCCATCAAAGTGCATAACATAGTACTCATGATGCAAGTTACTGTGACAA CAACATACTTTGGCCACTCTGAACAGATATCCCAGGAGAGGTATCAGTAT GTCGACTGTGGAAGAACACAACTTATCAGTTGGGGCAGTCTGAATATTT AAATGTACTTCAGCCACAACAGTAA

>hg38 refGene NM 001134232 range=chr7:12214811-12231975 5'pad=0 3'pad=0 strand=+ repeatMasking=none ATGGGAAAGTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGC TTATGATGGAGTCACATCTGAAAACATGAGGAATGGACTGGTTAATAGTG AAGTCCATAATGAAGATGGAAGAAATGGAGATGTCTCTCAGTTTCCATAT GTGGAATTTACAGGAAGAGATAGTGTCACCTGCCCTACTTGTCAGGGAAC AGGAAGAATTCCTAGGGGGCAAGAAAACCAACTGGTGGCATTGATTCCAT ATAGTGATCAGAGATTAAGGCCAAGAAGAACAAAGCTGTATGTGATGGCT TCTGTGTTTGTCTGTCTACTCCTTTCTGGATTGGCTGTGTTTTTCCTTTT CCCTCGCTCTATCGACGTGAAATACATTGGTGTAAAATCAGCCTATGTCA GTTATGATGTTCAGAAGCGTACAATTTATTTAAATATCACAAACACACTA AATATAACAAACAATAACTATTACTCTGTCGAAGTTGAAAACATCACTGC CCAAGTTCAATTTTCAAAAACAGTTATTGGAAAGGCACGCTTAAACAACA TAACCATTATTGGTCCACTTGATATGAAACAAATTGATTACACAGTACCT ACCGTTATAGCAGAGGAAATGAGTTATATGTATGATTTCTGTACTCTGAT ATCCATCAAAGTGCATAACATAGTACTCATGATGCAAGTTACTGTGACAA CAACATACTTTGGCCACTCTGAACAGATATCCCAGGAGAGGTATCAGTAT GTCGACTGTGGAAGAAACACAACTTATCAGTTGGGGCAGTCTGAATATTT AAATGTACTTCAGCCACAACAGTAA

# Ratolí:

>mm10 refGene NM 027992 range=chr6:13071744-13084326 5'pad=0 3'pad=0 strand=+ repeatMasking=none ATGGGAAAGTCTCTTTCTCACTTACCTTTGCATTCAAATAAAGAAGATGG CTATGATGGCGTTACATCGACAGACAATATGAGAAATGGATTGGTTAGCA GTGA AGTGCACA ACGA AGACGGA AGA AATGGA GATGTCTCTCAGTTCCCA TATGTGGAATTTACTGGAAGAGATAGTGTCACTTGTCCCACTTGCCAAGG AACAGGAAGAATTCCTAGGGGACAAGAAAACCAACTGGTGGCATTGATTC CATATAGTGATCAGCGGTTACGGCCAAGAAGAACAAAGCTGTATGTGATG GCGTCTGTGTTTGTCTGCCTGCTCCTGTCTGGATTGGCTGTGTTTTTTCT TTTCCCTCGATCTATTGAGGTGAAGTACATTGGAGTAAAATCAGCCTATG TCAGCTACGACGCTGAAAAGCGAACCATATATTTAAATATCACGAACACA CTAAATATAACAAATAATAACTATTATTCTGTTGAAGTTGAAAACATCAC TGCTCAAGTCCAGTTTTCAAAAACCGTGATTGGAAAGGCTCGTTTAAACA  $\verb|CCCACAGTTATTGCAGAGGAAATGAGTTACATGTATGATTTCTGTACACT|\\$ GCTCTCCATCAAAGTGCACAACATAGTACTCATGATGCAAGTTACTGTAA CAACAGCATACTTTGGACACTCTGAGCAGATATCTCAGGAAAGGTACCAG TATGTCGACTGTGGAAGGAACACGACTTACCAGTTGGCCCAGTCTGAGTA TCTAAATGTCCTTCAGCCACAACAATAA

#### Annex 1b. Resultat alineament en CLUSTAL.

CLUSTAL O(1.2.4) multiple sequence alignment

hg38_refGene_NM_018374 mm10_refGene_NM_027992	ATGGGAAAGTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGCTTATGATGGA ATGGGAAAGTCTCTTTCTCACTTACCTTTGCATTCAAATAAAGAAGATGGCTATGATGGC ***********************************	60 60
hg38_refGene_NM_018374 mm10_refGene_NM_027992	GTCACATCTGAAAACATGAGGAATGGACTGGTTAATAGTGAAGTCCATAATGAAGAT GTTACATCGACAGACAATATGAGAAATGGATTGGTTAGCAGTGAAGTGCACAACGAAGAC ** ****	117 120
hg38_refGene_NM_018374 mm10_refGene_NM_027992	GGAAGAAATGGAGATGTCTCTCAGTTTCCATATGTGGAATTTACAGGAAGAGATAGTGTC GGAAGAAATGGAGATGTCTCTCAGTTCCCATATGTGGAATTTACTGGAAGAGATAGTGTC	177 180

	******* ******** ****** ******** ******	
hg38_refGene_NM_018374 mm10_refGene_NM_027992	ACCTGCCCTACTTGTCAGGGAACAGGAAGAATTCCTAGGGGGCAAGAAAACCAACTGGTG ACTTGTCCCACTTGCCAAGGAACAGGAAGAATTCCTAGGGGACAAGAAAACCAACTGGTG ** ** ** ***** ** ****************	237 240
hg38_refGene_NM_018374 mm10_refGene_NM_027992	GCATTGATTCCATATAGTGATCAGAGATTAAGGCCAAGAAGAACAAAGCTGTATGTGATG GCATTGATTCCATATAGTGATCAGCGGTTACGGCCAAGAAGAACAAAGCTGTATGTGATG ****************************	297 300
hg38_refGene_NM_018374 mm10_refGene_NM_027992	GCTTCTGTGTTTTGTCTGCTCCTTTCTGGATTGGCTGTGTTTTTCCTTTTCCCTCGC GCGTCTGTGTTTTGTCTGCCTGC	357 360
hg38_refGene_NM_018374 mm10_refGene_NM_027992	TCTATCGACGTGAAATACATTGGTGTAAAATCAGCCTATGTCAGTTATGATGTTCAGAAG TCTATTGAGGTGAAGTACATTGGAGTAAAATCAGCCTATGTCAGCTACGACGCTGAAAAG **** ** **** ***** ****** **********	417 420
hg38_refGene_NM_018374 mm10_refGene_NM_027992	CGTACAATTTATTTAAATATCACAAACACACTAAATATAACAAACAATAACTATTACTCT CGAACCATATATTTAAATATCACGAACACACTAAATATAACAAATAATAACTATTATTCT ** ** ** ************ *************	477 480
hg38_refGene_NM_018374 mm10_refGene_NM_027992	GTCGAAGTTGAAAACATCACTGCCCAAGTTCAATTTTCAAAAACAGTTATTGGAAAGGCA GTTGAAGTTGAAAACATCACTGCTCAAGTCCAGTTTTCAAAAACCGTGATTGGAAAGGCT ** **********************************	537 540
hg38_refGene_NM_018374 mm10_refGene_NM_027992	CGCTTAAACAACATAACCATTATTGGTCCACTTGATATGAAACAAATTGATTACACAGTA CGTTTAAACAACATAACCATTGGCCCACTTGATATGAAGCAGATTGATT	597 600
hg38_refGene_NM_018374 mm10_refGene_NM_027992	CCTACCGTTATAGCAGAGGAAATGAGTTATATGTATGATTTCTGTACTCTGATATCCATC CCCACAGTTATTGCAGAGGAAATGAGTTACATGTATGATTTCTGTACACTGCTCTCCATC ** ** **** *************** **********	657 660
hg38_refGene_NM_018374 mm10_refGene_NM_027992	AAAGTGCATAACATAGTACTCATGATGCAAGTTACTGTGACAACAACATACTTTGGCCAC AAAGTGCACAACATAGTACTCATGATGCAAGTTACTGTAACAACAGCATACTTTGGACAC ******* ***************************	717 720
hg38_refGene_NM_018374 mm10_refGene_NM_027992	TCTGAACAGATATCCCAGGAGAGGTATCAGTATGTCGACTGTGGAAGAAACACAACTTAT TCTGAGCAGATATCTCAGGAAAGGTACCAGTATGTCGACTGTGGAAGGAA	777 780
hg38_refGene_NM_018374 mm10_refGene_NM_027992	CAGTTGGGGCAGTCTGAATATTTAAATGTACTTCAGCCACAACAGTAA 825 CAGTTGGCCCAGTCTGAGTATCTAAATGTCCTTCAGCCACAACAATAA 828	

#### Annex 2. Seqüències aa.

#### Humà:

>NP 001127704 length=274

MGKSLSHLPLHSSKEDAYDGVTSENMRNGLVNSEVHNEDGRNGDVSQFPY VEFTGRDSVTCPTCQGTGRIPRGQENQLVALIPYSDQRLRPRRTKLYVMA SVFVCLLLSGLAVFFLFPRSIDVKYIGVKSAYVSYDVQKRTIYLNITNTL NITNNNYYSVEVENITAQVQFSKTVIGKARLNNITIIGPLDMKQIDYTVP TVIAEEMSYMYDFCTLISIKVHNIVLMMQVTVTTTYFGHSEQISQERYQY VDCGRNTTYQLGQSEYLNVLQPQQ

>NP\_060844 length=274

MGKSLSHLPLHSSKEDAYDGVTSENMRNGLVNSEVHNEDGRNGDVSQFPY VEFTGRDSVTCPTCQGTGRIPRGQENQLVALIPYSDQRLRPRRTKLYVMA SVFVCLLLSGLAVFFLFPRSIDVKYIGVKSAYVSYDVQKRTIYLNITNTL NITNNNYYSVEVENITAQVQFSKTVIGKARLNNITIIGPLDMKQIDYTVP TVIAEEMSYMYDFCTLISIKVHNIVLMMQVTVTTTYFGHSEQISQERYQY VDCGRNTTYQLGQSEYLNVLQPQQ

#### Ratolí:

>NP\_082268 length=275

MGKSLSHLPLHSNKEDGYDGVTSTDNMRNGLVSSEVHNEDGRNGDVSQFP YVEFTGRDSVTCPTCQGTGRIPRGQENQLVALIPYSDQRLRPRRTKLYVM ASVFVCLLLSGLAVFFLFPRSIEVKYIGVKSAYVSYDAEKRTIYLNITNT LNITNNNYYSVEVENITAQVQFSKTVIGKARLNNITNIGPLDMKQIDYTV PTVIAEEMSYMYDFCTLLSIKVHNIVLMMQVTVTTAYFGHSEQISQERYQ YVDCGRNTTYQLAQSEYLNVLQPQQ

# Annex 3. Resultat blastn.

RID: B5G0BE69114	
Job Title:NM_001134232:Ho	omo sapiens transmembrane protein
Program: BLASTN	
Subject:Mus musculus trans	membrane protein 106B (Tmem106b), mRNA ID: NM_027992.3(nucleic acid) Length: 6099
Query #1: Homo sapiens tra	nsmembrane protein 106B (TMEM106B), transcript variant 2, mRNA Query ID: ref NM_001134232.2 Length: 1235
Sequences producing signifi	cant alignments:
	Max Total Query E Per.
Description	Score Score cover Value Ident Accession
Mus musculus transmembra	ane protein 106B (Tmem106b), mRNA 1501 2771 37% 0.0 76.41 NM_027992.3
Alignments:	
>Mus musculus transmemb	rane protein 106B (Tmem106b), mRNA
Sequence ID: NM_027992.3	Length: 6099
Range 1: 310 to 2346	
Score:1501 bits(1664), Expe	ct:0.0,
Identities:1623/2124(76%),	Gaps:126/2124(5%), Strand: Plus/Plus
Query 133 ACATGGGAAAC	GTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGCTTATGATG 192
111111111111111111111111111111111111111	
Sbjct 310 ACATGGGAAAG	TCTCTTTCTCACTTACCTTTGCATTCAAATAAAGAAGATGGCTATGATG 369
Query 193 GAGTCACATCT	GAAAACATGAGGAATGGACTGGTTAATAGTGAAGTCCATAATGAAG 249
11111111 111111	
Sbjct 370 GCGTTACATCGA	CAGACAATATGAGAAATGGATTGGTTAGCAGTGAAGTGCACAACGAAG 429
Query 250 ATGGAAGAAAT	rggagatgtctctcagtttccatatgtggaatttacaggaagagatagtg 309
1111111111111111111	
Sbjct 430 ACGGAAGAAATO	GGAGATGTCTCTCAGTTCCCATATGTGGAATTTACTGGAAGAGATAGTG 489
Query 310 TCACCTGCCCTA	ACTTGTCAGGGAACAGGAAGAATTCCTAGGGGGCAAGAAAACCAACTGG 369
11111111111111111	
Sbjct 490 TCACTTGTCCCAC	CTTGCCAAGGAACAGGAAGAATTCCTAGGGGACAAGAAAACCAACTGG 549
Query 370 TGGCATTGATT	CCATATAGTGATCAGAGATTAAGGCCAAGAAGAACAAAGCTGTATGTGA 429
111111111111111111111111111111111111111	
Shirt 550 TGGCATTGATTC	CATATAGTGATCAGCGGTTACGGCCAAGAAGAACAAAGCTGTATGTGA 609





Query 1610 ACACATCTTTCTGTATTAGTTATAGTTTTGTGAAATCTTTGTGTGATCTTCAAACATTAT 1669
1 - 1110111 100 0000 111000000000001
Sbjct 1779 AGTATGTGTTTCATGTATAACTTTGTGAGCTTTCTGTGTGATCTTCAAACATATT 1833
Query 1670 CATTTAATGTACAATACTGTAAATAAACTGTGCATGGCTTTTATACAGCTTTAGTAAATG 1729
Sbjct 1834 CCTTTAATGTACAATATTGTAAATAAAGTGCATGGCTTTTATACAGCTTTGATAAAGG 1891
Query 1730 TCAAATAAAGTGGTACAGACTCATTACAACAAGTTTCTCATAAAAAATACAATAA-ATA 1786
Sbjct 1892 TCAAATGAAGTACAGATTAAGAATAAAGCAGGTTGTTCATAAACAATAAGGTA 1947
Query 1787 GGAAAATGAAATTCAGAAACCCATAGACTGGGAATAGGTTCCAGTTACAGCTTGGATCTG 1846
Sbjct 1948 GGAAATTGAAATTAAGAAACCTATAAAATATCAGTAGGTTCC-GCTACATGTTGGATCTG 2006
Query 1847 GCATAAAATAAATTTGAAATAAAATATTTTGATGCTCCAtttttttaTGTTGCTTTTCAT 1906
Sbjct 2007 ACATAACATAGATGCACAGTAAAACATTTCGATGCTCTA-CTTTTTATATT 2056
Query 1907 ACTAAAGAATGGTGTAGACATGTTTTGCAACTGTTAGGTACCCAGTTATCAATTTTATCA 1966
111 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
Sbjct 2057AATTATATAGATGCTTTTCCCAGCAATTAGGTATCATCAATTTTATGA 2104
Query 1967 ATGTTTTAGAGGAGGAAATTAttttttttGGTAGAAATTGTTCAAGAAATCCTTAATTGAA 2026
Sbjct 2105 ATGTTTTAGGGAAGAAAACCATTTCTTT-CTAGAAATTAGTCAAGGAATAA 2154
Query 2027 TGTCATTAAATGATGGTGGCCAAAATAAAACCTATTTAGAAATTTAA 2073
110010 1001 10000000 11110000
Sbjct 2155 TTTCATTGAACACTGGTGACTACATCAAAATAAAACCTATAGTTTGCTTAAAAAATTTAA 2214
Query 2074 TCACTTTGCACATCACTTGGAATATGATGCCTCTAGTAGTTACttttttatagttttcta 2133
111 11 11111 11 11 11111 11111 1111 1111
Sbjct 2215 TCATTACCCATCATCCTGAGT-CGATGCTTCTAGCAGTTACAGTAAACATTTAT- 2267
Query 2134 cttttggttttatttaaaattgttttCAAATATAGATTATTGACTTATTCAACTTTGCTG 2193

Sbjct 2268 TTTTTAATTTTGTCTAACATGGTTTTCAAAT----ATGATGGACGTATTCATC-TTGTTG 2322

Query 2194 ttttatattttcagtatcattttt 2217
Sbjct 2323 CTTTATATTTCCAGTGTCATTTTT 2346
RID: B5X08TP6114
Job Title:NM_018374:Homo sapiens transmembrane protein
Program: BLASTN
Subject:Mus musculus transmembrane protein 106B (Tmem106b), mRNA ID: NM_027992.3(nucleic acid) Length: 6099
Query #1: Homo sapiens transmembrane protein 106B (TMEM106B), transcript variant 1, mRNA Query ID: ref NM_018374.4 Length: 12545
Sequences producing significant alignments:
Max Total Query E Per.
Description Score Score cover Value Ident Accession
Mus musculus transmembrane protein 106B (Tmem106b), mRNA 1508 2777 36% 0.0 76.43 NM_027992.3
Alignments
Alignments: >Mus musculus transmembrane protein 106B (Tmem106b), mRNA
Sequence ID: NM_027992.3 Length: 6099
Range 1: 304 to 2346
Tunge 1. 304 to 2340
Score:1508 bits(1671), Expect:0.0,
Identities:1628/2130(76%), Gaps:126/2130(5%), Strand: Plus/Plus
Query 321 CCTCAGACATGGGAAAGTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGCTT 380
Sbjct 304 CCTCAAACATGGGAAAGTCTCTTTCTCACTTACCTTTGCATTCAAATAAAGAAGATGGCT 363
Query 381 ATGATGGAGTCACATCTGAAAACATGAGGAATGGACTGGTTAATAGTGAAGTCCATA 437
Sbjct 364 ATGATGGCGTTACATCGACAGACAATATGAGAAATGGATTGGTTAGCAGTGAAGTGCACA 423
Query 438 ATGAAGATGGAAGAAATGGAGATGTCTCTCAGTTTCCATATGTGGAATTTACAGGAAGAG 497
Sbjct 424 ACGAAGACGGAAGAATGGAGATGTCTCTCAGTTCCCATATGTGGAATTTACTGGAAGAG 483
Query 498 ATAGTGTCACCTGCCCTACTTGTCAGGGAACAGGAAGAATTCCTAGGGGGGCAAGAAAACC 557

Sbjct 484 ATAGTGTCACTTGTCCCACTTGCCAAGGAACAGGAAGAATTCCTAGGGGACAAGAAAACC 543







Query 2322 tttctacttttggttttatttaaaattgttttCAAATATAGATTATTGACTTATTCAACT 2381
Sbjct 2263 TTTAT-TTTTTAATTTTGTCTAACATGGTTTTCAAATATGATGGACGTATTCATC- 2316
Query 2382 TTGCTGttttatattttcagtatcattttt 2411
Sbjct 2317 TTGTTGCTTTATATTTCCAGTGTCATTTTT 2346
Range 2: 4006 to 5767
Score:389 bits(431), Expect:6e-110,
Identities:1250/1869(67%), Gaps:163/1869(8%), Strand: Plus/Plus
Query 4259 TAATACTGCTGGACTAAGATTTTGGTAGCATTGTTTTCTAAAATATTT-TAAATG 4312
Sbjct 4006 TAATAGTGATGG-CTAAGATTTTGGTAGCTTTGAGTTGCTATCTGAAATATTTCTAAAAG 4064
Query 4313 GAGAATGAACACTTATAAAATGCTTTGGAACATAATCTTTAGCTTAATTTTCTGTTA 4369
Sbjct 4065 TAAATTAAACGATG-TAGAATCCTTCAGAACCAAAGCTGGAGCTTAATTTTTATGTGTTA 4123
Query 4370 AAATTTAGTACCCCTTCATCATTCCAATAAAGATAAGACTGATCCATTGTCTAAGGAAAT 4429
Sbjct 4124 ATATTTAATACTTCACAATCATTCCAATAAAAATAAAACTGACATTTTTGGTGTGAAT 4181
Query 4430 TATTTATAAATAATAGAGATTAATTTATTTGAGATTTGAAATAAGAATAGTATGAAAATA 4489
Sbjct 4182 TATTTATAAGTAAGATTATTACATTTGAGATTTGAAAATACAGAGC-TGAAAATA 4234
Query 4490 TTAGATACCACATAAATTGTTTGAAATTACT-GAATAACCATCTTAAGTATGGA-ACATT 4547
Sbjct 4235 CTAGACATGAGATAAATTTCTTGAAATTGCTTGAAAGACTATCTTGCCTGAGGTGACATT 4294
Query 4548 TAAATGGCTATATTT-TATTTGTGTA-CAGTTTTTCTGTGCCTTGTTAGGCCAGT 4600
Sbjct 4295 TCATAGAACATAACTGTATTTTGTTATCAGTTTTCCTTTGACTCCTGTTTACCCGGTCTT 4354
Query 4601GAAGCAATTATTTTCTCTAAGAAAATGACAATAAAATATAACACACTTCAGA 4652

Query 4653 TTGTCTGATTTACAGTTTGGAAAGGACACCGCAATGTTCAAATAGGTAGG
Sbjct 4415 TCTTATAATTTGCACTTAGGAAATGGTGGTGAAGTGTAAAAGGATGTGGGAGGTTGACAT 4474
Query 4710 CAAAAACACAATTAAAGTAACATATTAGGAGACTTGAAACTTCAGCCTAATAAATCCTTC 4769
Sbjct 4475 CCAAA-CACCGTCTAAGTAACATTAGGACAATTGGAACTTGGCCCTAATGGG-CCTTG 4530
Query 4770 ATGGTTCTTAGCCTTATTATTGTGATATAATTCTAGATATTTTCTTGGAGGGCATGTGCC 4829
Sbjct 4531 -TGGTTTTTAGCCTACTATGGAATAATTTTGGCTATTATGTTGGCAGGTGTGCC 4583
Query 4830 CAACTCTCCCGCACCCCATTTTGTTTGTCTTTTAAAGTTCTTAGAATAAACAGTTCTTTA 4889
Query 4890 TATAATAATTATATTTAAGAAAATAGTTTGTTAGGTAC-TTTTTAAAAGATGTAA 4948
Query 4949 AT-TTTTAAATTTACAAATACATATGGGTCTTTGATAAGCAATAGGAATTGAATT
Query 5005 AAGTTACTAGGGTTATAAGCAAAAGGTTGCTTACCATAATGTCATTAGGTCACGATTTTT 5064
Sbjct 4748 TAGCCATT-GGTTTATAATCAAATGGTAAACCGTGATGCCTGAGACACTAAAAT- 4800
Query 5065 AGCTCACATCTGGAAGCAGCAACTACTTGGCTCAA-GTACATATAAGAGTAATTAGTTTT 5123
Sbjct 4801 -GCCATAGCTGCTTGGCTCAAAGTGTGTCTTAGAGTGGGCAGCCTT 4845
Query 5124 ATTCTCTCTTT-TTTATAAAATCGGGTTTCAGATGAGATG
Sbjct 4846 ATTC-CTCTGACTTTGTGAAACTAGATTTTAAATGAAACATTTATCTTTAACT-TTCTAA 4903
Query 5183 GGAAAAATTTTACATGTTTGAGATGGTGGAGTAAAAAGACTGTTAAACATTTCTTTTAAA 5242

Sbjct 4355 AATGAAGTAATTCTTTTTTCTTAAAACCTATTAAAAGAGTAAAATATAACTGACTTCAGA 4414

Query 5243 AAATTATTTTTACATTACAACAA-TATATTTATGATGTGTTCAGATCAAAAATTTA 5297
Sbjct 4960 GTTGTAATTTTAGATTAAAATAAATGTATTTGTGATATACTTACT
Query 5298 ACTTCTGTGTCCCAGATCTACTTTCAAAGTGAGATT-TTCACTTGTCAGCTTAAATTTCT 5356
Sbjct 5020 ACTTCTATATCAAAGACCTATTTACATTACAGTCTTCA-TTCACAGTTTCT 5069
Query 5357 GACTAGAACTAACATTTGTGTATTTTTGTGCTTAGTCGGAATACAAATTTCACAGTGGAT 5416
1 1 11111 1111111 1111 1 111 111 111111
Sbjct 5070 GGTTGCAACTACTTTGTGTGGTTTTTAGCTTGCTTAGAGAACAGGTTTCACAGAAGAG 5127
Query 5417 TTTTGAAGTTTGTCCTTAAATTGGATAAAATCAAGTG-ATTAAAGTTACTAAAGAGATAA 5475
Sbjct 5128 CTCTGACGCTTATCTTTAAATTCGATAAAAGCAACAGCAATGGGATTACTGTAGGAACAC 5187
Query 5476 AAATGGTAATTTCCATTTTTAAAAGTAATTTGGTTGTGTTTATAGTTATTTGTACAAGTA 5535
Sbjct 5188 AAATAG-AATTTCCATGTTTTAAGCTGTTCTTGTTCCTTTTTACATGTG 5235
Query 5536 TTTATCACAGACTCTAAATTGAAAAATGTAGTATGATCTATATTTGACCCTAAAAATGTT 5595
Sbjct 5236 TTAA-CACAGACTCCAAGCTGAAGA-TACAGTGTGGGTTCGACCCTCAAAGCAGT 5293
Query 5596 GGATTAATTTAACAAATATGGCAGATTTTTCATAACTAAGTCTTAAGTCTTCTAA 5650
Sbjct 5294 GCATAGACAACGTAGCAATATTATGAGGAGCTTCATAGTTAAGTCTTAACTATTCTAG 5351
Query 5651 AAGGAAGCTGTTACCCTTCTGTTTTTAATTACATTAATTGAAATGTGTTTTAAGAGATAC 5710
Sbjct 5352 AAGGAAGTTGTTGCC-TTCTGTTTAATTACATTCAT-GAAATGTGTTT-AAGTGAAAT 5406
Query 5711 AATTTCAGCATATTTTATATATTaaaaaaacaaaaaGGATTAGTATTGAGCCAGTGGCCA 5770
Sbjct 5407 ATTTTCAGGATATTTTGTATGCTGTAAAACAAAAAAGGAATTGTATTGTGCCAATGGCCA 5466
Query 5771 AAAGGTAATATTACTACCATGTAGACTGTTATAGTTCAAATTGTCCCACTTCACCCAGAA 5830

Query 5831 TTTTAGAAACTAGAAGTCTGGGAGGTACTATATCAGCTGTAGTTGGGTAATTC-CAAGTG 5889
Query 5890 CTGATAGTACTATTCATCTTTTTTAT-TATTGTGTCAGATGAAACAAATGCCAAGT 5944
Query 5945 TGCAAAATATGCAGATTTTATTATATAATGGTTTTAGGCATAAATTATTAACAAGCC 6002
Query 6003 ATGCCTTATGTGTTTCATCTTATATTTTTCTTTAGAACTAAACTATAACAGATTTTGGAA 6062
Query 6063 AATGATTTG 6071          Sbjct 5759 AATGATTTG 5767
Range 3: 5858 to 6074
Score:207 bits(229), Expect:4e-55, Identities:183/223(82%), Gaps:8/223(3%), Strand: Plus/Plus
Query 6214 CCTCCATCATGACACACTTACTACATTTATGAATTGAGCAGTTCTGTAATTGTAATTATT 6273
Query 6274 ATTGCTGTTCATGTAACAAAACATGCTTATAATAGCAAACA-AATAGAAATGCCCCCAAA 6332
Query 6333 ATGCTAttttttttAATTCAGTTATAACTGTTACTCTTGTAGTTGTGTATGACGCAATAAA 6392

Sbjct 5467 AA-GGTAATATTACTACCATGTAGATGACAGTTCAAATTGTCCCACGTCACCCAGAA 5525

# 

Sbjct 6032 ATTTGTAAAAAACACTTTAGCATGAAAAATAAAATTTGTATCA 6074

## Annex4. Alineament resultant CLUSTALO A-B.

CLUSTAL O(1.2.4) multiple sequence alignment

genomicA genomicB	cagaagaattgcttgaaccagggaggtggaggttgcagtgagcagagatcacgccactgcgctgggatgtggggagcagtgttctgaggctgagcag-gac  * **** * ** ***** * ** * * *	60 40
genomicA genomicB	actcctgcttaagtgacagagtgagactccatctcaaaaaaaa	120 90
genomicA genomicB	tgtgcttgagtaataccacccactctggcaaatcttaaaaaagctcttggccgggtgcag tgagcctgtgtcctataacttattgcaggctgttagaagcaggcagac ** ** ** ** * * * * * * * * * * * * *	180 138
genomicA genomicB	tggctcatgcctgtaatccccagaagaattgcttgaaccagggaggtggaggttgcagtg tactttctggatgctttgctgcttagaatttttttctgcca * * * * * * * * * ****** **	240 179
genomicA genomicB	agcagagatcacgccactgcactcctgcttaagtgacagagtgagactccatctcaaaaagatatcctaggtcatcactctATGAGTGTGGATCCAGCTTGT ** * ** * * * * **** ***** *****	300 221
genomicA genomicB	aaaaaaaaaattcctattatgtgcttgagtaataccacccac	360 245
genomicA genomicB	<pre>aagetettggeegggtgeagtggeteatgcetgtaateceATGGGAAAGTCTCTTTCTCA GCATCatgggaggagetgtetetaagatetetaaagtgaetttgaggeettttgetea</pre>	420 303
genomicA genomicB	TTTGCCTTTGCATTCAAGCAAAGAAGATGCagttccccatttctgtcgccacacctctga ttgtcttggatattagcccttggcacccttttagtcacgctaatcccccta ** * * * ** * * * * * * * * * * * * *	480 354
genomicA genomicB	<pre>gatggtgcctgtgtctgtcattgtttcttgaatcaatctagacctcagttctaaagaacc gcaagtggttgctccacagcctgtttatattcctctctaataatgc * *** ** * * **** * * * **** * * *</pre>	540 401
genomicA genomicB	ctaaaaactctgtccgtgaatcttgggggaaggaggaagtcaatgtaaaatacttccata ttttttattctctgccacatggctggctacgagttttccaaacttgtatgcttt * * *** * * * * * * * * * * * * * *	600 455
genomicA genomicB	ttgtatttctaagatgtctatttcccctttgtgattattttgactgcaagtgtccgtg gtttcccttttaaatgtaagtttcagctttaagtcatttctttgcatggggagcagatga * * * * * * * * * * * * * * * * * * *	658 515
genomicA genomicB	aatcttgggggaaggaggtcaatgtaaaatacttccatattgtatttctaagatgtc atcatatggtgagaggaagtcacagagagagactaggatgtggtaccagactcttaag * * * * * * * * * * * * * * * * * *	718 575
genomicA genomicB	tatttcccctttgtgattattttgactgcaagATGAGTGTGGATCCAGCTTGTCCCCAAA caatcaaatctcacgtgaactaactgagcaagaagtgacttatcaccaag * * * * * * * * * * *****	778 625
genomicA genomicB	GCTTGCCTTGCAAGCATCagttccccatttctgtcgccacacctc gggtgttaaccattcatgagggatctgcccacatgatccaatcacctcccaccaggaaat * ** * * * * * * * * * * * * * * *	827 685
genomicA genomicB	tgagatggtgcctgtgtctgtcattgtttcttgaatcaatc	887 736
genomicA genomicB	accctaaaaactcagttccccatttctgtcgccacacctctgagatggtgcctgtgtctg AGCAAAGAAGATGCtgcccacatgatccaatcacctcccaccaggaaatcacattgggaa * * * * * * * * * * * * * * * * * * *	947 796
genomicA genomicB	tcattgtttcttgaatcaatctagacctcagttctaaagaaccctaaaaactc tcac***	1000 800

# RID: B63R11NS11N Job Title:genomicA\_vs\_B Program: BLASTN Subject:genomicB ID: lcl|Query\_63835(dna) Length: 800 Query #1: genomicA Query ID: lcl | Query\_63833 Length: 1000 Sequences producing significant alignments: Max Total Query E Per. Description Score Score cover Value Ident Accession genomicB 95.3 188 10% 2e-23 100.00 Query\_63835 Alignments: >genomicB Sequence ID: Query\_63835 Length: 800 Range 1: 201 to 251 Score:95.3 bits(51), Expect:2e-23, Identities:51/51(100%), Gaps:0/51(0%), Strand: Plus/Plus Sbjct 201 ATGAGTGTGGATCCAGCTTGTCCCCAAAGCTTGCCTTTGAAGCATCA 251 Range 2: 701 to 750 Score:93.5 bits(50), Expect:6e-23, Identities:50/50(100%), Gaps:0/50(0%), Strand: Plus/Plus Query 401 ATGGGAAAGTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGC 450 Sbjct 701 ATGGGAAAGTCTCTTTCTCATTTGCCTTTGCATTCAAGCAAAGAAGATGC 750 Annex6. Blastx. RID: B65Z619G114 Job Title:genomicC Program: BLASTX

Subject:NP\_001127704 length=274 ID: Icl | Query\_64215 (amino acid) Length: 274

Annex5. Megablast A-B.

Query #1: genomicC Query ID: Icl|Query\_64213 Length: 21894

Sequences producing significant alignments:

Max Total Query E Per.

Description Score Score cover Value Ident Accession

NP\_001127704 length=274 135 606 5% 9 e-39 85.14 Query\_64215

Alignments:

>NP\_001127704 length=274

Sequence ID: Query\_64215 Length: 274

Range 1: 1 to 73

Score:135 bits(339), Expect:9e-39,

Method:Compositional matrix adjust.,

Identities:63/74(85%), Positives:67/74(90%), Gaps:1/74(1%)

Query 8096 MGKSLSHLPIHTCKEDGYDGGTVSDNMRNGLVHSESHGEDGRCGDVSQFPYVEFTGRDSV 8275

MGKSLSHLP+H+ KED YDG T S+NMRNGLV+SE H EDGR GDVSQFPYVEFTGRDSV

Sbjct 1 MGKSLSHLPLHSSKEDAYDGVT-SENMRNGLVNSEVHNEDGRNGDVSQFPYVEFTGRDSV 59

Query 8276 TCPTCQGTGRIPRG 8317

TCPTCQGTGRIPRG

Sbjct 60 TCPTCQGTGRIPRG 73

Range 2: 226 to 274

Score:86.7 bits(213), Expect:4e-22,

Method:Compositional matrix adjust.,

Identities:40/49(82%), Positives:46/49(93%), Gaps:0/49(0%)

Query 16460 VFLRVTVTTSYFGHSEQISREKYQYVDCGGNTTYQLGQSEYLNVLQPPQ 16606

+ ++VTVTT+YFGHSEQIS+E+YQYVDCG NTTYQLGQSEYLNVLQP Q

Sbjct 226 LMMQVTVTTTYFGHSEQISQERYQYVDCGRNTTYQLGQSEYLNVLQPQQ 274

Range 3: 154 to 198

Score:76.3 bits(186), Expect:1e-20,

Method:Compositional matrix adjust.,

Identities:40/45(89%), Positives:42/45(93%), Gaps:0/45(0%)

NNNYYSVEV NITAQVQFSKTVIGKARLNNIT IGPLDMKQ++T

Sbjct 154 NNNYYSVEVENITAQVQFSKTVIGKARLNNITIIGPLDMKQIDYT 198

# Annex7. Regions promotores.

>hg38 refGene NM 018374 range=chr7:12206294-12211293 5'pad=0 3'pad=0 strand=+ repeatMasking=none tttttttatttgctgtttccctaggtttagtgttctttaaatttgtttt tgttttgtttttaggattcactgaatttcttgaatatatggattt acatattcagtcagtttttggagatttctaagtttttatcttttcaatatt $\verb|tcttctatcccctttctgctccttggattccaagtacatatgtgctaaat|$ gatttgatattatcctaaagatatcagatgctcccttccatttgtccttg attttgctctttatattcagtttatataatttctactgaccgtctcaagt ttacaggtttttttccctctgttatgtccaatttggtgataatgctaaaa agtgaactttttacttctaatatttatttctaatatttcaacttgctttt ttttccattttttatacagatgctttaacatatctatcaaagtgatttta  $\verb| aagtctctgccagataataccaaatctgggccatttctgtattttcccct| \\$  ${\tt attaatcattttctctttgaccattggctcacattttcttgctccttcat}$ gtctcataatctttattatatgctagatattgtataaaagaaaacagtaa ataacatgtacctcaaaaaacatcttgccattttttctatcaagattatt  $\verb|gtttggaaggctgaatcaaatctttcaacagtgagtcaaaaacccacatt|\\$ ctgggttttgttgaagttttgattcagtttatttactattgctttcaaat  $\verb|atgcttgagttcttggcactggcaaaatctcaagattaatgtgcacctac|$ tagctcattccaccaaactattcaatactttcttagctcaaacacctagc  $\verb|ttcca| at a tctcca cagg| ttgttctgtttactctccagtcttgccggtca|$  $\verb|tttctgtgcctcaggagaatcctgggcagcctgccaccctgcctccagcc|\\$ ttcacagagctgctgcagtacactggttaaaggcctagaatctgcaaaga aatttcttcagcattcatgccctaccccatgcctttaacatatgacattt  $\verb|cgttctatcactggaacgacatgagattgtaatctatcatcctggtccac|\\$ acacaggggtgtcattcggcaggtctcccttcggccctgtttatggtgca ttcctccttctcccactgttttgtaggtgattaaagcaactctaattcta ttctctcttaggaagctctccttatcttttggatttaagtgtacttaaat a a a c c t c t c t g t g t g t g t g a g a a a a c a g t t t t t a t a a c a t $\verb| aaatccta | \verb| attcga | ctctgtgttttcctta | tttatattcgga | acacctc$ ctcaaggatttctggacccaattctcctcttttcagcagcagtgatgatc acttagcaaaagagtgaaaataccctcttttccccccctaaccagttaac tttactcaccgtcatcacttatctttgtgtagtaaaagttgaggacagaa ttcactcttccaaatttaatacagatattcatgccacagtggttaatagc tgtagctttgcagtcaaaatatccgagttctagttgctagctgtgtggtc atgtgcaagtcataatacctaggatcctctatttccactgtttgaaataa gatatgggataataacagaacctaatccatagcatttctataaaaattag gccaagtgttattgaactcctaaaattattcttactagaaattatgatta acagaggaaatatagaagatcctgcctaagaaggagtacagagacataac caagagtttcagataggtaagttatttgcagaaattaataaagacctctg cttttaaaataattggaatgacaaagatgtgtcaatagagtcaggagttt actgcctgtgaatgtaagtcaggtggcacagcgggaaatggtagttttgc ta atggtag ttttgctatgtatctggggcactatctctgaaaatcagccagacaaacttcaatcttttcaatccctggtttccaatgtaacctatccagg tttctaacataatctgaccagcatatcagtggaagggggtgagctgagag agacttatatattaacatttgacaaattatatgtttcaaaataattatgt $\verb|tccttttctgcttataatttttaacagctaatttctagaaaagtaatttt|\\$ tgcaaaatttttagttatggctgactgctattaggatttgggtgatttac cattaaaagagataaaagagaattgaaatgagagataaggctgttttcaa gatttagtacaacctagagaaatcccttagcttcagcatcatactaaata taaccagaaatcattaagaaagaatgttcttctattcaaacttatcccagactgttaaaattactggcctttatatctgatagcacctagaccactactg aactcggaactcaagaaatcactgttaatcaaataattggaagcttttca gaaaattttcctttcaaaatgtgcttcaatgaaaaataaggcataggaac aaatgtaccaaacattcaatatctgtctttaaagtacttccttgttatat  $\tt ggatgataaatttgtaatcataatatctaatatttactgattgctctgca$  $\verb|ggtatcagctcccatccataaccctttgagacagacattattactatctt|\\$ cattttgcagataataaaaattaggtataaagaaggctaagtattttgcc cactcttacagagattttgtatatctctgtcaggctgggctcattttcag  $\verb"gccatatggctcccaaggctgtgttcccaaccctgctactgaactgcttc"$ ttacagcaacattctcccaggaagacttattcctatgtgaattccaggaa  $\verb|tttggataaggaactgtgctatatggccagcacgttttaagttaaatgat|$ gaggttgagaaaatactaaatactcccttaagaattaaagaaaaaagtaa ctttttcacttaagaataatatatattacattatagaaccatttgcctat ttaacaataataaagaaaaaacatccatgctctcaaactacaggcaactg

 $\verb|tttatattttgtatatttctttccatttcaaggcagatatgtaatattt|\\$ 

tatatctatatgttatctatatgtgaatatagtttacatcctattacaat acctcatatcctatactttgcatcctgattttaattttatatcactccgc gtataacagccttataagatggtttttactggctttataaaaactcaata gatggctattccataattttaaaaactcagtaattccaaggggaacatca tatctccacaggtggactgtcaataattttgagaaaaattttcccccatg attctgatttgttttaaccaacctattaattttgaaatttcaaacagtgt  ${\tt agcggttgaaaaataatgattttatcaatgtcccttgttggacattcagt}$ ttatttaaatggatacacctcatacccaaatctttttagagttctcatta  $\verb|ggtttaggatacttctgaaagggtggaattgctggaccaaacgatgtgaa|\\$  $\verb|cattttaatagtcttgatacatactgactgtctgccagaaaacttaggag|\\$ ttttaaatctccgacaacattgtatgagaaagctcattatctcacatatg gatctacagtaatcctcttaaattgtatatcgttctgacttgtatttcct acttttacatagcttcatttcccaattcctgttagaattccctgattcta  ${\tt acaggatcacactgatcctgttagaagagagaaatatatgactctcactt}$  $\verb|ccttgctcctgtgactgtaagaatgcctaccattcattaaacgttaaact|\\$ ctccgcaggaatgagactagagtgcccttaatattattaccggcatctca ttgatccctcaaaacgactccttgtcgttgttcttatcttctaagtgaaa tgacctagacgttggggggggggcagccccaacccacagcgaagagcttaa $\verb|gtactgggatccgagacgggatttcacacacctgtaactagcaccagagt|\\$ taaggggtggggagggcagcgtgggcaaagcgaaacgaaaccgagcaaa aacaaaaactacggccttgccgcttgctgtctccttctagttggccagtt tctaaattaaaatagaggtagctttgctgctgtcagcggcgtgtgtacgg accagtttattccattcctaaggaccagactgtcagcgacaactcgcatt $\verb|gcgtgagcgagggctgctcagctgaaagctgaggcagatggtgcacat|\\$  $\verb|ttataccctttgcaaaaggaaatggtctgatatgggaaataggaggagcg|$ actgttcctaggtaattcgtggctacagtggacactttgaagtctggggg acgcgaaggtaatgaaacctgaagagcgcacaatctcacacgatcgacgc $\verb|ctctgggctcaaacaggaggaagaaggacgcatgcgtcacgcgcacgcca|\\$ ggggtgtccctccgggagcgctctgcgcaggcgcggacgcaggttacagc agcgcttggcctctgctgatgccgtcgttatcctacccctccccgtccc

>mm10 refGene NM 027992 range=chr6:13064759-13069758 5'pad=0 3'pad=0 strand=+ repeatMasking=none

tgtgtgtatgtgtgtgtgtgtgtgtgtgtgttatgtgtgtgtg  $\verb|ttataaagctcccctgagaaatgtttgttgtcttagttcagatatttctg|$ agctgtacttctgatctaatcagtattagggtgtgcatacaataaaccat  $\verb|ccctgtctgactgagatcggtgttcattcgtatggtttgtagtgctactc|\\$  $\verb|tcagccctcaacaatatattttaattctttatttggacaaaatatctgct|$ attccaagtttaaaaaaattattcatgccacagtggtgaataacatgtgc ttttctgatttctagttatacaatttgatagctgtgtgttcatatacaag gtttataagtatgcagggatgtgtgtatggaaatttgggacaatacaggg tttctttttcaaacattctctaccatagctatagtaagataggatctctc  ${\tt actgagtctggacctcaccaatttgccagtgagcaccactgatccttgca}$ tctctgttttccagagctgagatcacaaataccaacctctaggcttaaat atttaatgtgtgttctggtgaattgaactagtttcttcatacttatggaa  $\verb|caaacactttacagactgagtgatctctcccgtctttagtttctctgttt|\\$ aaaataaaattcagataataatagaatgtaatccaaagacttcccataga aattaaaaagagatgaactgaaatacttcatatactgcatgacacaacaa actcattcatttattaaacatgacctattttgtaacattttttcactaac tggtttaaacatcttaatacatacagagaaatttgcctctctaggtttga agcaatgaagatgtaagtcaggatatacagaagattcttatgctaaaaat ggtttcttagggatgtgaaccaaaggctcaaagggatgagatgtttgcag  $\verb| aatgtaacaaaggatattgaagaggaaacacaaaggtgtagtcacaga| \\$  ${\tt accaagaacttgctatcagtgaatgtagggcaaatgaccacagggaataa}$  ${\tt tacttttgctatgtatctgggaaactatcacaggaattcagccagaaaca}$ ctccagttctttaacttctaattttctattatagaaggttgagtaaaata agccacaccaaaaagacaaaaagaaaattctttatatacacagagtataa gtttgtgagtgcatctataaaaataattaaactcagtttgctaatgttac ccaqccaqcttqaaacttaaaaqtqcaqqctacqacaqacctqcatacta acaataaaccatatacttcagaacgattgagagagtaaattatgaattat ttgtctgtttataagttttagcaacaaatttctaaggaagtgacatttga  $\verb"aatttggctgccagctgttaatatgtgggtgagtctcattcaaggaaatt"$ atgagaaacatggaaggaacatgcatgttttgaagatttaacctagcata gaagaataccttatttcaacacccacgaaaaagaggtttaatcagatcac aacttctgttcagttacctcatactatttaaaacattgtttctaatatct  $\verb| aatagcatgtagactgacatggatctcaaaatttcaaagaaaaagttgtt| \\$ gacattttccaaaatttttcttttaaaatattctttaatgattaaaaaaa tttactgtttgtggataaaaactttgtcacaataatatctaattgttgtg ttttataaaaatataaagagaaggaatatgtttggtggaggtaaggtagg tgtgggggaaggaggtgcctctgcagggccatgctgaggtattgcttccc  $\verb|ctggagggaccagccatgcaatgtattcagggcatggggaggggagttga|\\$ agaggctgtgaccacttgcagagagaggggaatgcggagcctgt aggaggggacaagcagcccttttatagagtcaggcacacctggcaacag  $\verb|gtaactgcggggcagagcctgacaaaatgccaacactaacagctgctata|\\$  $\verb"cttacaaccttttaaaacaagctccaacagggccataccttctaatcgtg"$ ccactccttgggcagagcatatacacaccatcacattctgcttcctggcc  $\verb|cccataggcttgtccaaacatatgaatctatgggggccatacctaaacat|$ agcata ataa aaccat cacag t g tatgag cat g taact g agg cacta tagaaaaataatatagaaagacaggtgtaattatggaggtggggaaaagacc $\verb|cttactctggaggctagttggagtctgtcttcagttgagagttaaggatt|\\$  $\verb|ccagcata| attaacactta| ctgtgatgttgcagacatagaaacaatactc|$ attttaaaactgtaaaaataacaacaaaaaacaacacccaatagaaaga  $\tt gtgcataagacatcatgtatgttctcagtccttgatattttaagaagctt$ aaacttttatcttaactttctgcacccctaggtcgctttacattgtgagt tgtaatcctattcaagactccacaggagctctaatcccatttacgttcct ta at gaacctt ta aa gat tactgaa aacccaccccaa aat gtat g t g g $\verb|ctactataaagacaatgaagtgtgattctctctttgaggagcccacagcca|\\$  ${\tt tgttctcagatgagatttatacattctctgagtccctttcatttctattt}$ aagtctatgcttaaactctatgtttaaatgccttttaatacacatcaagt  $\tt gggcttcatattggatcttattgaagggaaggaaggctgttctcacagca$  ${\tt agttttagggcaactagtgtgcaacccaaggaaccacatctcaaaagcaa}$ tcattttatcaagtgcactgctggtgtgacttaatcaggtatttagttta tgtgtatttagtttccttgcagtggtttgaataggaacagcctctggacc ggcttaaatggaggaggtgctgactagggagagggccttggggtctaagg  ${\tt agctaattcacttccctgctgtctctgatgtcgaactctaagctcctcca}$ gtatcatgtctgcctggttgctgccatgtttcctgccaggagcataacgg  $\verb"gctaaacctctgaaactgtaagccaaccccaaataaatgtattctttata"$ agagttgccatggtctacttcgaagctattgttaactctattgaaatcct ${\tt aagaaactggttacacactgcacacaactttactttagaattctcattat}$  $\verb"aatttaggatgaatctcacagagtgaaattgccggacctaaggaggtgaa"$ tgttttaaatagtcttaaaacatcctgcttatgtagatggaaaatacaca  $\verb"gctctcacctcaaaaggacaaaggatttattctaaagccaatatgaggaa"$ ccatgacctgaaaacaaagacttgggctattccaaataccaatgtcccaa tgtgataacaatttcatgaaacttttatatacatagaagatggtcataaa tcaaaatactttccaaatacatacaaqqcaqtttaqaaqaqcqqqacaaa  $\verb|attgggagctcctcgcccagtgcagttgctttttccagtagagaaggaa|$ agatgcttacttcccagttataactctgttaattttctaggaatttcacc ${\tt agaaaccccatttatagggaagctattaaactcctttagcaaccgcatct}$  $\verb|gttcttgctttcaattttatcttattataatcccatccaggaatcttatg|$ agccacttaatacatcttgattatcaggaagacagaaaagaggtcataac $\verb|aacctttgactataacactggcgagccactaaaatgagccactgtagcct|$ caactcactgtaaattatgactggacaatgaggtgcatggattgggacac tcctttaacaactcacttggtcatgagctttggggtacaactcttattgc $\verb|atgcactgaata| atgtgaattta| agtacaaaatcaaaacaagatta| aacc|$ a agg cgg ggg ggg gg gg t cttcccgg tgacatta atttcta aatgaaaactcaataacaaaattctggcctgcaactctgccagaaatgtgcaccaa  $\verb|ccggctcattctaaccccaggaaggaagttttgtgtctgcaaatctagac|$  $\verb|ttgagaacacgatcgctcaaaattgcgacggtgcacattcctccccttta|\\$  $\verb|caaaaggaatcagcctggtggaggggaaaagggaaaaccgattattcgta|\\$  ${\tt agccaggcgcaattagtactattttgaaactttccagtctagagaagaga}$  $\verb|caggtgacaaaaccagaagctttcaccctggcaacttcccttcaaaccgg|$ 

>rn6\_refGene\_NM\_001004267 range=chr4:39512679-39517678 5'pad=0 3'pad=0 strand=+ repeatMasking=none gccaggaaaccagaaggcaggaggtgaaggagggcagagggctga ggcaaaaggcaccagaatgaaaggcaaggaactgggtgaaaggtatgt

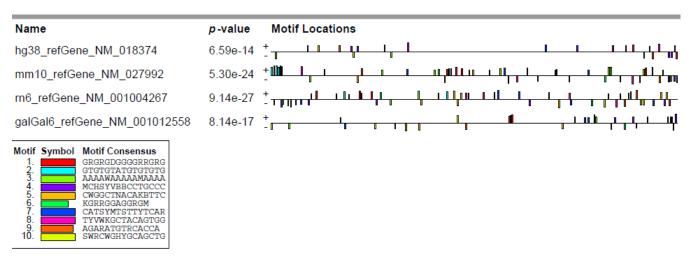
 $\verb|ctgcaccagtcccaggcagggcagtggccactggttttgttcccttccctc|\\$ ccctgcctgctgccctccctgtcgcccagatggccagatacagcagtggt  $\tt gacagcagcagcagaagttaaaattattaactagaaaatggcagcca$  $\verb"ggccagatcaccaggtggtcacatggtgaacttggggagtgagctctggg"$  $\verb|ccgcgactgtaggtaaacagttcacctatgcctaggatttggcaactaca|\\$ agaaggaactacctcagaggagagagaaaatctcgcccaagagaaaatg  $\verb|tcctaga| at gagggt cagtga| aaa agaccaagtcataaagaccgatatctc|$  $\verb|ttctctgaagtttgggctaaagagcaaaggcctctctatgtggtggtggg|\\$  $\tt gggtgggggggggggtgggatgtgaacctgaggagtttctaatccaagtat$ cggctccaaatgtgttttataaaaatatagagagaaggaatatgtttgct  $\tt ggaagttaaggtaaggtgtggaggaatggggtgcctttgcaggcccattg$ ctggcgcatcgctttcccacctgaggaccaacaccacaggacagttgcta tggttcctttagtagctcgatatatcaggcatgagcgacgtgggttggtg  $\tt ggaggtgaggtgtgagtgttgagggtgggttcgagggggtattttagtg$  $\verb|ctaggttttggtgtcagggtttaggactatttctgaggagagagtagggc|\\$ tgaaggagtgggtgactgtttaccttgtgggggtcatcagtttgtga $\verb|catggtgttgctggctgattttctgtttaattttaactatctgtgctgct|\\$  $\tt ggcgaggagggtgggagggacatggaagatccggagccatagatgataga$ tgggtggtgacacagatgaactatgagggggtacaaggattgatattact $\tt gatggtttacatttggtgtttttgtagtttgccgagagagggaaaggggt$ 

ctggtttatagtgagtcaggcacacctgactgttgccaggtaactggggg  $\tt gtggagcttagacaaaatgccagcactaataatgctagacctacgaccct$ gtaaaacaagcattattgctatctcaattctaaaagcaatagacatatgt ataaagaatgaggttttctttattttccaggctgtttacctactttgtag cttagttcatcctcaggcaagcagccttctaaggcaataccactaaattt a caggacttaccttctagagattcattattgaattctagtcacgtggataaagactgccaaaatgacaatattgatagagacaattctgtgaaaatacac  $\verb|ccttagatattcctttaaggaaggacttattttgcattcaagaataatac| \\$ aggtcagcctatagaaataggcacaacttcaacattgtatacaataaaat  $\verb|atttattttaaagtctctcaaaaggcaactggtggggatttctgtccct|$  $\verb|tgtccaaaaaaaaaaaaaaaaaatagtctaattaagagattggaaattgt|$  ${\tt taccctgaccccattccagcttcctcttagctcggggtcattataacctt}$ catgaaaacagtttagatgacaccgagggcaaagtttattgctgaagaat gtgaggcattccacctactgagcatggacaaaggtcaagagaccactgca  $\tt gaggaaagctggctaagggattagggtgatgatgtccagagaccttgtgc$ taactgacctacatgttcaggaaatctttgtctgaaacaacttcttgaaa tggtatttccctatccaggtgtgcttcaggtccattttgagtaactctta aggtatgtgtgtaccgtgggtgtcttaggggtttactgctgtgaacaga $\verb|catcatgaccaggacaactcttacaaggacaacgtttaattgggactggc|\\$  $\verb|ttacaggttcagaggttcagtccattatcacccaggtagaacatggcagc|$ ctcaaggcaggcctggcacaggaggaactgagagccttacatcttcatct tcaggctgctagcagaatactggcttcagctaggatgagggtcttatagc  $\verb|cacagtgacacacctactccaacagggccacactttctaatcatgccatt|\\$ ccctgggcaaagcatatacaaaccattaatcctacttcctggtccccata  $\verb|ggcttgtccaaacatgtgagtaaacacagcataataaagccatcacagtg|$ ggtgagggtgttattgaggcactgtacaaaaataatacagaaaggcaggt  $\tt gaagttatggggtcgggggtgggtgctccttattctggaatctagctga$  $\verb| aatctttcaccagcttagagttaagggttccagcacaattaatattcact| \\$ gtgatgttgcaaatagaaacattatccatttaaaagctgtaaaaataaca ctcagtccttgatattttacaaagttcttaagaacaatacttttctttta  $\tt ggtaaagatatcttaatcttctgcacccctaggttgctttatattgtcag$ gtatgtcgctacagtaaagacaatgactatttcctcagaagtccacag ccatgttctcagatgagatttatacattctttgagcccctttccttttca taaaagtctgtgcttgaaatatatgtttaaatgccctttaatacacttcaagtaggcttcatattggatcttattgaagggcaggaagactgttctcgcagcaagttttagggcagttagtgcaacacaaaggaccacatctcaaaagct  $\verb|attaattcacccagtgcactactggtgtgactaatcaggtatttagttta|\\$  ${\tt tgtgactggtcacagtggtttgaataggaatagcctcctcaacctgtttg}$ a aggtttggctcatagggagtggcacagttaggaggcgtggctttagaatgggtgtggctttgttgggggggggtgctgactaggaagtaagctttgaggt gtaaggagccaattcactttctgttgtatgtgaactctcaagcagaacca  $\tt gcaccatctgcctgcaggaagataatggactaaacctttgaaactgtaag$ ccaggcccaaagagttgccgtggtcgtggtccacttcgcagcaatagaaa tcctaagatattggtcacccactgcacgcaactttactttggaattctca  $\verb|ttatcattcaggatgaattctacagtggacctgaagagatgaatgtttta|\\$ gtcttgaaacttccttctgtagatggaaaatacacagctctcaccttaaa  ${\tt aggtctaagagtttattttggagccaaatgtgagggaccatgacctgaaa}$  ${\tt acaaaaactcgggctattctgaataccatgtcccaacgtgtaacaatttc}$ atgaaacttatacacataaaagaagatggtcataaattaagatactttcc aaataaaaacaaggcagtttagaagagcggggcaaaattggtcgctcctc  $\verb"gcccagtccggttgctttttgccagcagagaagaagaacaacaacaatca"$  $\verb|atggatgcttaaccctttcccacttagttatagtccattaattttctagg|$ aatttcaccagtaaccccatttatagggaaattattaaactttagcagct  $\verb| aagta acctttta agata acactcg agattcacta a aatgagccacagta|$ gcctcaactcacagtgagttatgactggacaatgaggtgtgtggggtggag aggtcctgaggatactcctctaagaactcacttggtcatgagtattgggg  ${\tt tacaactcttattgcacacacagaataatgtgaacttaagtacaaaatca}$ aaacaagattaaaccaatgcgggggtggggtgcgttttcccagtgacag aaatttctaaatgaaaacaataacaagatgtgtgtaactctgtcagagat gtgcaccaactggttcatccttaccccagggaggaagtcttgcggctgca aatgcagcattgaaaacaaggccgctcaaaactgcgacagtacacatttc  $\verb|tcccttcacaaaagaaatcagccttatggaagggaaaaggaaaaccgat|$ ttttcgtaaggcagacgcaataagtactatttctaaacttgccagtctag agaacagacaggaggcgaaaccaggagccttcccccagcaacttcccttc agggtgccaaagctgggaaagggcgcatgcgtactacctattccaggctc  $\verb|ccagctccttccatgggcggactacgcaggcgcacgcgcaggctccc|\\$ ggggtacccggctcagctgatgcagttgttgtcctacccctcccccgccg ctctcccggcctcactcgggccggcccttagccccgccctgggaccggga  $\verb|ctccgtgaccccgtcctgcggctcgccagcgcaggagcatcccgggaccg|$ 

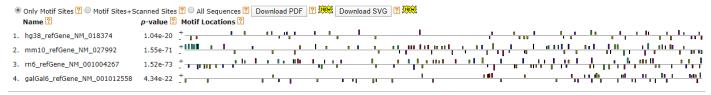
 $\label{lem:control_state} $$ \sim \frac{M_001012558 \text{ range=chr2:}26565971-26570970 5'pad=0 3'pad=0 strand=+ repeatMasking=none } {\text{cagctgcaattgctgctatgtttcttaggtaaagacaagtggtttggaat gtgatttgtaataaccgtgttctgaaagaagctattcagaagcattaaac }} {\text{cataatcactgggtcattcacccaactgatcagaagatttattattcttt gtctagatctgtgggttgttggcatttttgtatctccccatcaatatcca gtttcttgaatttccagtttgtttttttttcctcctccagaagaaaggtg} $$$ 

agaatatacaaacagaattaagatgggctatttttcttcaactcctggga  $\tt gcacacaatgcagcaagcaatggataatacatagcatcagaactgt$ aatcatctcattcgtcaactaatgcaaaatttaaggtttgcacacgtaatgaacaaggagaaactataaagtatacactgcagaagaccatagagtgttg  $\verb|caagaatgacag| ttgtcggtagctgtgcaatatatcagaaatacatcagt|$ tataaaaggctgtttatgttttattcattcaaaataactcagagcacagg  $\verb|ccgtatcatcagaaaatacatagcaatgaaagtacctgtgacacaccatg|$ cttaagcattaaatgcatctaaaaatgtttaccacagaatatcattaaaa tcagaaattctgaaatacagagaattcttcacataggtggaaaaggatgt  $\verb|ttcaaaaaacagaactcttaaaaaatccgaacagaccaaataaagacagtgg|$ aatttttgatattcatatttttaattcttgtaattctaatttaattagta caggcacagctcaaaggaacactggggtgcagtaacaggtatgttgctga tcagataacaggcagggtcatgagctatgttgtcctgtgcctggaataga  $\verb|tttgcctcagattacatacacctacatgagcgtcgcaactattgtataga|\\$ ttggtttgatgtgttctgggattaggatgatttctgaataaaataagact gttgcccttgtaatagatcaagggcaaaatcaataaacaattatagttgt tcttaatttttatcaggatagcttatacctctctttcctgagtttctcaa  $\verb| aaagaaaatcagagtaaagggaatcagcattttcacttggttgtcccagt| \\$ gagcaggtgatagaagtctaaaaaaattgttcctgtgactgatggagatg aaggaagaagtagtccacataggcagctgtaacagatgtgcaaagccta ctgtgccttatataaaccagtggtaataaccagtctaaagcagttacaag ctttcttaaaggccttctcccctatcagcaactggtcagtgcccacattc tctcacattgctgttttatattctagattagatagaaatcattgctttta  ${\tt tgttgctttatttatttattttgtggggtttggtagtttaggttctttc}$  ${\tt tgatttgtttgattttttgctgaggagaagcttggatatatgttagagat}$  ${\tt aaaaactgagctaaaatgctgtatctacctcagcattcagatagcatgcc}$  ${\tt acccattttcaggctagcagactgtatgaaaacaagactcagtaactttg}$ a aggtgttagccagtttcagctgagtcacagagataagaaagtttatacaaatttcataaagatagataaccaggcagaagagagacaagggattgaatg tttggaagccattgtgtaataactttctatgcagtaagcacatttctaac  ${\tt aaattctatttgtgaacatggcagcctgcatgttactgtcagaatactct}$ gcaggaaaagacatgagttgtatgcagttcttttgttacaatttgggtaa acagtcatctgagaggtagatctataggaaatgaggctgcattagtttca tcagtttgaagtttcttcggataagcaatgcaatgaggttgaagaagaaa taaaattaattagtctctcaagcatctgaggtcatgcagatatgcactgggagtctgcacattggtgcagttgattgctcttgagattgctaattccagc tcttgcaagaacctgactcacttgtcatatccgagccacaaaactcaact tgaaacctgattcatcacttggctttctttactgatatactactggaagt ataaaatgcacctggttactgatctatgagaactaagagcacttgcagctgtcccataactcagttcaaaggtgatgatctcaaattccctgttcctatc atttgattgtttccatttcatacccctcacagtgccatttgtgctgtaca  $\verb|tcacttgcctatcatgcatttttattatttttttgtatctgtgtttaagt|\\$  $\verb|atgca| atccca gtcca gtggtggtta gca ca gtcca atca gtttca gga a$ ctggcaatattggatgctgtgcagtgtaaaatgtgtaaaatactccttct ataaccaaaggtattttgtttcaatcagtccaagctcagtggcccacttc agtgacgctttcaggcatctcatcccatatttaagcacttctaatgtact tgtaatgtgtacatcttgttatcggtaataccacatatttctcatgtttt  $\verb|tcatgcttgcatagtgagcgtaagactttacaggaccttcatattattgc|$ tttaagacaactattaaggagcttaaggcacataattggtgagcaagatt tttctagtgtttcaacttaaattttctttaacatgcactttctaaatgaa  $\tt gagagtaggagagggagggagggaaggaaggaaggaaaaggcaaat$ gaagggaaaaagctttcctaatgtatcaaatctacagaaggaaaggctat ggcagtttggaaatgtaattaatacaaaacagtttattgtttaaagtaac agact caa a acct cat g cag at tt caact g tt g g g at ctat cat g g a a a g a ctat cat g g a a a g a ctat cat g g a a g a ctat cat g g a a g a ctat cat g g a a g a ctat g cat g a ctat g a ctat g cat g a ctat g a ctat g cat g a ctat g a ctat g cat g a ctat g catagaaacaatgtctcaggcaactatgtaacatcctgatcggcatttggcct tctagataagtttcaatgttggatgaaaactgctgcaatcaaaggtgtaa aactgtaatttgacccaagactgcactgtatttcaaacttgctaggagaa taaatttatattgagatactctgtcagagtaaataactctgagtagccag $\verb"aattcagtgtgaattcccaaaagccattccaaaaacctttctgctagactt"$ actcctcacgtctcctgtagtataatgattcagatcaatctgaatgactg acattattatctgatactattcaaaaggcggagactgtgttctcattttc tgtttggatagctggaaactctgatactgtttgatgtggatcaatataaa  $\verb|cttgagactgaaccaaaagtcaatagccagtgaagccagtagccaggctt|\\$ accaaattcacctcatctgacacttgttgctgaacatgtcatgttcatac aggttccaaacaagccagggttctgttcaaaggtttttatgtataattttgtatgtaggaacccacagagtaccatggtcatccatgctgcactggcagc  $\verb|tttgatggggacctcaggaaacttgaagacctgcaaaagtgttggctgag|$ gagggacaaagaagaccatgacatggcagctttgccactactttcagaca gcctctcctttacatgaactggctaaccaggagtgaggatgattgctaaa tggctcaggtcatgatttgtgcagaccatttttttctgagtgcgtatttt tgcaggtgagttattttctttgcctattctttcctggacacagagcccaa catgagcaatactgccagcagggctcgcacctgcagcagctctggactgg  ${\tt tgttagaggtgtcgtgcctccagagcagcctggagccatgccctgtcctc}$ atgctcaccccatgctgtcataatgcctatttccttatcctctcccttga agtctgcccttatgtttgcccttggaattccgtacatggcctccttcagg 

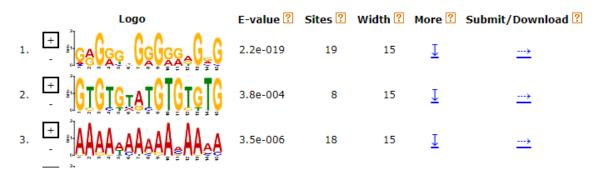
#### Annex8.Resultats MEME.



#### MOTIF LOCATIONS



# Annex8b. 10 millors motius de 30.



24.	+ 2 CACTGGACATGAGG	9.9e+005	2	15	$\overline{1}$	<u></u> >
25.	+ allocacicoc	1.4e+006	2	9	$\overline{1}$	<u></u> >
	+ JCAGGAGCATEECGGG	1.8e+006	2	15	$\overline{1}$	<u></u> >
27.	÷ jorgcactactact	1.8e+006	2	14	$\overline{1}$	<u></u> >
28.	7 <sub>n</sub>	1.8e+006	2	14	$\overline{1}$	<u></u> >
29.		1.8e+006	2	15	$\overline{1}$	<u></u> >
30.	+ 2 CTATGTATCTGGG	1.8e+006	2	14	Ī	<u></u> >

#### Annex9.

FGENESH 2.6 Prediction of potential genes in Homo\_sapiens genomic DNA

Seg name: human

Length of sequence: 37571

Number of predicted genes 1: in +chain 1, in -chain 0. Number of predicted exons 16: in +chain 16, in -chain 0.

Positions of predicted genes and exons: Variant 1 from 1, Score:115.993872

	C	DSf		CDSi		CDSI		CDSo <	Þ	PolA	TSS	
1 1 1 157			5000	100	000	3 4 56           15000	78 	20000		9 10 11 12 1	3 14	15 16
1	+	1	CDSf	157	-	286	28.30	157	-	285	129	
1	+	2	CDSi	10376	-	10458	7.43	10378	-	10458	81	
1	+	3	CDSi	12800	-	12857	6.33	12800	-	12856	57	
1	+	4	CDSi	14362	-	14447	3.34	14364	-	14447	84	
1	+	5	CDSi	15128	-	15189	2.40	15128	-	15187	60	
1	+	6	CDSi	15526	-	15655	6.39	15527	-	15655	129	
1	+	7	CDSi	16764	-	16828	6.62	16764	-	16826	63	
1	+	8	CDSi	17225	-	17406	12.24	17226	-	17405	180	
1	+	9	CDSi	23771	-	23865	2.10	23773	-	23865	93	
1	+	10	CDSi	25045	-	25142	0.60	25045	-	25140	96	
1	+	11	CDSi	26262	-	26281	-1.21	26263	-	26280	18	
1	+	12	CDSi	27296	-	27427	8.29	27298	-	27426	129	
1	+	13	CDSi	28008	-	28732	33.29	28010	-	28732	723	
1	+	14	CDSi	30780	-	30932	9.89	30780	-	30932	153	
1	+	15	CDSi	31931	-	31994	13.04	31931	-	31993	63	
1	+	16	CDS1	33682	-	33875	1.90	33684	-	33875	192	
1	+		PolA	33923			-4.47					

Predicted protein(s):

 TCTCAACTCAGTTTTGCGGAGGACATTTCTGCTGATGAAGATGACCAAATCCTCAGTCAA GGAAGCAGAGTCTTTTGTGTAGAGGAAGAGGACAGTGAAAGCAGTCTTCAAAAGAGAAGA AGGAAGAAGAAGAAGCACCACCTGCAGCCTGAAAATCCAGGCCCAGGGGGTGCAGCC  $\verb|CCATCCCTGGAACAGAACCGGGGCAGGGAGCCCGAGGCCTCTGGGCTGAAAGCCCTGAAG|\\$  $\tt GCACGTGTGGCCGAGCCAGGTGCAGAGGCCACGTCCAGCACTGGGGAGGAGAGTGGCTCC$ GAGCATCCTCCAGCCGTCCCCATGCACAATAAAAGGAAACGGCCACGGAAGAAGAGCCCG  $\tt AGGGCCCACAGGGAAATGTTGGAATCAGCAGTGTTGCCCCCAGAGGACATGTCTCAGAGT$ GGCCCGAGTGGCAGTCATCCTCAGGGACCTAGAGGGTCCCCGACAGGTGGAGCCCAACTC CTAAAAAGGAAGCGGAAACTTGGAGTTGTGCCCGTCAATGGCAGTGGCCTGTCCACGCCG GCCTGGCCTCCATTGCAGCAGGAGGCCCTCCCACAGGCCCCGCAGAGGGGGCGAACAGC  ${\tt CACACCACGCTGCCCCAGCGCAGGAGGCTGCAGAAAAAGAAGGCAGGGCCCGGCAGCCTG}$ GAGCTCTGTGGCCTGCCCAGCCAGAAAACAGCAAGTTTGAAAAAGAGGAAGAAAATGAGA  $\tt GTGATGTCAAACTTGGTGGAGCACAACGGGGTGCTGGAGTCCGAAGCTGGGCAACCCCAG$ GCTCTGGGAAGCAGTGGGACTTGCAGTTCCCTGAAGAAGCAGAAGCTGAGGGCAGAGAGC GACTTTGTGAAGTTTGACACCCCCTTCTTACCAAAGCCCCTGTTCTTCAGAAGAGCCAAG AGCAGCACTGCCACCCTCCAGGCCCTGCCGTCCAGCTAAACAAGACACCATCCAGC AAGAGTATCTTGGTCAGTCCCACGGGCCCTTCTCGAGTGGCCTTCGACCCTGAACAGAAG CCCCTCCACGGGGTGCTGAAGACCCCCACCAGCTCACCTGCCAGCTCACCCCTGGTGGCC AAGAAGCCCCTGACCACCACCAAGGAGAAGGCCCAGGGCTATGGATTTCTTCTGA >FGENESH: 1 16 exon (s) 157 - 33875 758 aa, chain + MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY CMWVODEPLLOEELANTIAOLVHAVNNSAAOHLFIOTFWOTMNREWKGIDRLRLDKYYML  ${\tt IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG}$ GKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVDQSPFVPEETMEEQKTKVG DGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERGRDDCGTFEDTGPLLQFDY KAVADRLLEMTSRKNTPHFNRKRLSKLIKKFODLSEGSSISOLSFAEDISADEDDOILSO GKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRKKKKHHLQPENPGPGGAA  ${\tt PSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEHPPAVPMHNKRKRPRKKSP}$  ${\tt RAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLKRKRKLGVVPVNGSGLSTP}$ AWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLELCGLPSQKTASLKKRKKMR VMSNLVEHNGVLESEAGOPOALGSSGTCSSLKKOKLRAESDFVKFDTPFLPKPLFFRRAK SSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDKSILVSPTGPSRVAFDPEQK PLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF

## Annex10.

>FGENESH: 1 16 exon (s) 157 - 33875 758 aa, chain +

MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY

CMWVQDEPLLQEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYML

IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG

GKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVDQSPFVPEETMEEQKTKVG

DGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERGRDDCGTFEDTGPLLQFDY

KAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQLSFAEDISADEDDQILSQ

GKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRKKKKKHHLQPENPGPGGAA

PSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEHPPAVPMHNKRKRPRKKSP

RAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLKRKRKLGVVPVNGSGLSTP

AWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLELCGLPSQKTASLKKRKKMR

VMSNLVEHNGVLESEAGQPQALGSSGTCSSLKKQKLRAESDFVKFDTPFLPKPLFFRRAK

SSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDKSILVSPTGPSRVAFDPEQK

PLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF

>/tmp/05\_08\_20-11:44:37.fasta|GENSCAN\_predicted\_peptide\_1|897\_aa

MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY

CMWVQDEPLLQEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYML IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG GKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVDQSPFVPEETMEEQKTKVG DGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERGRDDCGTFEDTGPLLQFDY KAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQLSFAEDISADEDDQILSQGKHKKKGNKLLEKTNLEKEKGKQELQGALGGGCLMTTRDLWFLPLSPKISGNGTISVPYV FINGQKEGFQSQLGMEEVGPDDKGSRVFCVEEEDSESSLQKRRRKKKKHHLQPENPGPG GAAPSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEHPPAVPMHNKRKRPRK KSPRAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLKRKRKLGVVPVNGSGL STPAWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLELCGLPSQKTASLKKRK KMRVMSNLVEHNGVLESEAGQPQALAAHLNLPEPPVCRQRHWAAHTSESQVRDPVSLWVA VSCCTRNECPGPASVVLCVKPELCRMEGLSASAVRKTAGRRGSSGTCSSLKKQKLRAESD FVKFDTPFLPKPLFFRRAKSSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDK SILVSPTGPSRVAFDPEQKPLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF >human\_1|geneid\_v1.2\_predicted\_protein\_1|622\_AA MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY CMWVQDEPLLQEELANTIAQLVHAVNNSAAQACVWFFSRIKVFLDVLMKEVLCPESQSPN GVRFHFIDIYLDELSKVGGKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVD QSPFVPEETMEEQKTKVGDGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERG RDDCGTFEDTGPLLQFDYKAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQ LSFAEDISADEDDQILSQGKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRK KKKKHHLQPENPGPGGAAPSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEH PPAVPMHNKRKRPRKKSPRAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLK RKRKLGVVPVNGSGLSTPAWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLEL CGLPSQKTASLKKRKKMRVMSNLVEHNGVLESEAGQPQALVRWEHPQASSPQRHSLASMG LHCLLRGRVGAGGQASGLSSS\*

#### Annex11.

>FGENESH: 1 16 exon (s) 157 - 33875 758 aa, chain +

MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY

CMWVQDEPLLQEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYML

IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG

GKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVDQSPFVPEETMEEQKTKVG

DGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERGRDDCGTFEDTGPLLQFDY

KAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQLSFAEDISADEDDQILSQ

GKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRKKKKKHHLQPENPGPGGAA

PSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEHPPAVPMHNKRKRPRKKSP

RAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLKRKRKLGVVPVNGSGLSTP

AWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLELCGLPSQKTASLKKRKKMR

VMSNLVEHNGVLESEAGQPQALGSSGTCSSLKKQKLRAESDFVKFDTPFLPKPLFFRRAK

SSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDKSILVSPTGPSRVAFDPEQK PLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF >/tmp/05\_08\_20-11:44:37.fasta | GENSCAN\_predicted\_peptide\_1 | 897\_aa MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY  ${\tt CMWVQDEPLLQEELANTIAQLVHAVNNSAAQHLFIQTFWQTMNREWKGIDRLRLDKYYML}$ IRLVLRQSFEVLKRNGWEESRIKVFLDVLMKEVLCPESQSPNGVRFHFIDIYLDELSKVG GKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVDQSPFVPEETMEEQKTKVG DGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERGRDDCGTFEDTGPLLQFDY KAVADRLLEMTSRKNTPHFNRKRLSKLIKKFQDLSEGSSISQLSFAEDISADEDDQILSQ GKHKKKGNKLLEKTNLEKEKGKQELQGALGGGCLMTTRDLWFLPLSPKISGNGTISVPYV FINGQKEGFQSQLGMEEVGPDDKGSRVFCVEEEDSESSLQKRRRKKKKKHHLQPENPGPG GAAPSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEHPPAVPMHNKRKRPRK KSPRAHREMLESAVLPPEDMSQSGPSGSHPQGPRGSPTGGAQLLKRKRKLGVVPVNGSGL STPAWPPI OOFGPPTGPAFGANSHTTI PORRRI OKKKAGPGSI FI CGI PSOKTASI KKRK KMRVMSNLVEHNGVLESEAGQPQALAAHLNLPEPPVCRQRHWAAHTSESQVRDPVSLWVA VSCCTRNECPGPASVVLCVKPELCRMEGLSASAVRKTAGRRGSSGTCSSLKKQKLRAESD FVKFDTPFLPKPLFFRRAKSSTATHPPGPAVQLNKTPSSSKKVTFGLNRNMTAEFKKTDK  ${\tt SILVSPTGPSRVAFDPEQKPLHGVLKTPTSSPASSPLVAKKPLTTTPRRRPRAMDFF}$ >human\_1|geneid\_v1.2\_predicted\_protein\_1|622\_AA MAPAMQPAEIQFAQRLASSEKGIRDRAVKKLRQYISVKTQRETGGFSQEELLKIWKGLFY CMWVQDEPLLQEELANTIAQLVHAVNNSAAQACVWFFSRIKVFLDVLMKEVLCPESQSPN GVRFHFIDIYLDELSKVGGKELLADQNLKFIDPFCKIAAKTKDHTLVQTIARGVFEAIVD QSPFVPEETMEEQKTKVGDGDLSAEEIPENEVSLRRAVSKKKTALGKNHSRKDGLSDERG RDDCGTFEDTGPLLOFDYKAVADRLLEMTSRKNTPHFNRKRLSKLIKKFODLSEGSSISO LSFAEDISADEDDQILSQGKHKKKGNKLLEKTNLEKEKGSRVFCVEEEDSESSLQKRRRK KKKKHHLQPENPGPGGAAPSLEQNRGREPEASGLKALKARVAEPGAEATSSTGEESGSEH PPAVPMHNKRKRPRKKSPRAHREMLESAVLPPEDMSOSGPSGSHPOGPRGSPTGGAOLLK RKRKLGVVPVNGSGLSTPAWPPLQQEGPPTGPAEGANSHTTLPQRRRLQKKKAGPGSLEL CGLPSQKTASLKKRKKMRVMSNLVEHNGVLESEAGQPQALVRWEHPQASSPQRHSLASMGLHCLLRGRVGAGGQASGLSSS\*

# Annex13.SNPs RRP1B.

chr21	43659829	43659830	rs225448 0	-	
chr21	43660136	43660137	rs73362750	0	+
chr21	43660254	43660255	rs35000523	0	+
chr21	43660278	43660279	rs9978671 0	+	
chr21	43660467	43660468	rs78030818	0	+
chr21	43660590	43660591	rs178743 0	-	
chr21	43660687	43660688	rs78427898	0	+
chr21	43660720	43660720	rs34256469	0	+
chr21	43661117	43661118	rs73905589	0	+
chr21	43661485	43661486	rs170445 0	-	
chr21	43661714	43661715	rs11330761	0	+
chr21	43661715	43661716	rs79698070	0	+
chr21	43661725	43661726	rs35519182	0	+
chr21	43661729	43661730	rs77321313	0	+
chr21	43661730	43661731	rs11330762	0	+
chr21	43661730	43661731	rs78878629	0	+

chr21	43661739	43661740	rs57248208	0	+
chr21	43661919	43661920	rs13052462	0	+
chr21	43661930	43661931	rs67287505	0	+
chr21	43661942	43661943	rs76650127	0	+
chr21	43661943	43661944	rs35522463	0	+
chr21	43661971	43661972	rs79432021	0	+
chr21	43662086	43662087	rs76643017	0	+
chr21	43662088	43662088	rs68105436	0	+
chr21	43662088	43662089	rs74886708	0	+
chr21	43662096	43662096	rs72009683	0	+
chr21	43662106	43662106	rs35823612	0	+
chr21	43662107	43662107	rs72212204	0	+
chr21	43662144	43662145	rs75365894	0	+
chr21	43662340	43662341	rs9979482 0	+	
chr21	43662625	43662626	rs225449 0	_	
chr21	43662660	43662661	rs78356453	0	+
chr21	43662795	43662796	rs178744 0	_	
chr21	43662820	43662820	rs35948230	0	+
chr21	43663244	43663245	rs76690582	0	+
chr21	43663317	43663318	rs7283699 0	+	
chr21	43663551	43663555	rs10590039	0	+
chr21	43663552	43663553	rs3787976 0	+	
chr21	43663552	43663556	rs57250024	0	+
chr21	43663554	43663555	rs3787977 0	+	
chr21	43663556	43663557	rs691748 0	-	
chr21	43663556	43663557	rs67420624	0	+
chr21	43663556	43663558	rs1620215 0	+	
chr21	43663556	43663562	rs57323059	0	+
chr21	43663556	43663564	rs61243535	0	+
chr21	43663557	43663558	rs36033318	0	+
chr21	43663562	43663563	rs8133786 0	+	
chr21	43663564	43663565	rs60279758	0	+
chr21	43663568	43663569	rs60745406	0	+
chr21	43663586	43663590	rs72216559	0	+
chr21	43663587	43663591	rs72172023	0	+
chr21	43663590	43663592	rs72232474	0	+
chr21	43663597	43663601	rs10590040	0	+
chr21	43663598	43663599	rs28377560	0	+
chr21	43663598	43663602	rs71878824	0	+
chr21	43663600	43663601	rs3787978 0	+	
chr21	43663826	43663827	rs76031955	0	+
chr21	43663937	43663937	rs11402831	0	+
chr21	43663937	43663938	rs66687826	0	+
chr21	43663945	43663946	rs61440193	0	+
chr21	43663946	43663946	rs34349454	0	+
chr21	43663947	43663947	rs67848320	0	+

## Annex14.

**CNS** retrieval options:

```
Remove gaps
                    Add
                              extra bases upstream (5') and downstream (3') of CNS
>Human Mar. 2006 chr21:43659925-43660040 (+)
AACACAAACGTATAGTACAAAATGT-AACAAATAAGTAGTGTCTACCTGTCTCCCATGTA
GATACATATACAGGATTTGCTTTAAAAAAAAAAAAAACATTAAAAACACTGACCTA
>Mouse Jul. 2007 chr17:31982234-31982339 (+)
AACACAAAATGTA-TACAAAATAGAAAAAAATAAGTAGTGT----CTGTTTCCTATTTA
TATACACATACAGTATTTGCTTTAAAAAGA-----AACTTTACAAACACTGACCTA
= length = 117bp, identity = 76.1%, type = UTR
>Human Mar. 2006 chr21:43660184-43660269 (+)
{\tt CAGCCTC-CAATATTGCACAACTTCACCCAAGTCAGGTGTTCTTGTTGGACCCC-ATCAT}
GAAATGCATAAA----CGTCAGCAGCAGCGGA
>Mouse Jul. 2007 chr17:31982457-31982548 (+)
CAGCCCCTTGGTATTGCACAATTCCC-CCAAGTCAGGTGTTCTAGCGGGACCCTGATAAT
GAAATGCATAAAAATCTGATAATTAGCAGCAGA
  length = 93bp, identity = 72.0%,
>Human Mar. 2006 chr21:43660818-43661021 (+)
CCCAGACACG-----CCCCTCAATTATC---TTTCTTCCTAAAGTTTCCAGTCCCTACT
---AAAAAGCCAAAACACCTAACGTATTGCTTATTTCGCTTCTAGAAAGTTCTTGGC-TT
TGAGGCCAGA---TGTCTTCACCTCCTCTGAAGTTATTGCT-GTAAGAGTCA
>Mouse Jul. 2007 chr17:31982939-31983161 (+)
CCCA----CGTGACATACTCTCAATTATTATTTTTTTTCTTCAGAAAGTT-----TCCCTACT
\verb|CCTAAAAAGCCCATACACCAAACGTATTGCTTGTTTCACGTCTAGAAAGTTCTTGGCTTT|\\
TGAGTCCGGAAACCATCTTCACATACTCCGAAATTATTGCTTGGAAGAGTCA
= length = 232bp, identity = 71.1%, type = UTR
>Human Mar. 2006 chr21:43661050-43661293 (+)
```

 ${\tt TCACTGCACCAGGACAAACGTGCCTAGGGAGCAGGGCATCAGGTCCTCCATCTCACAGTC}$ 

```
CCCCTGCAGCAGCCCCAGGGGCTCACAACCTGGGGCCAGC----CTGGCCAGGCGTGGTG
GGGGCACAGCGGGGGGGGGGGGGGCCGGTGCCAATGTGCAGGTGTGTCCAGGAGCT
\tt GCGCCGCTGAGGCCACCGGGGACGCGCCGGTCTGCAGGAGTGGGGGCGGCAGCAGCGGGA
>Mouse Jul. 2007 chr17:31983228-31983474 (+)
TCACTGTACCAGGACGAATGTCCCCCGCTGGCCAGAGGTCAGGTCCTCCATCTCACAGTC
CCCCTGTGGCAGCCCAGCTGGATCACAGCCTGGGGACAGCCTGG-TGAGGCACTGTGGCA
\tt GGGGCCCAGTGGGGAGGGCCACTGGGCCAGCACTGATGTGCAAGTGGGTATCCAGGAGAT
GCGCAGCAGACGCCACAGGGGACATGCCAGCCTGGAGAAGGGGTGTTGGCAGCAGTGGAA
TTCCAGAC
  length = 248bp, identity = 71.4%, type = exon
>Human Mar. 2006 chr21:43661328-43661425 (+)
CGGGTGCAGCGGCC-----GGGTGGTGCTGTAACTGGAGCAGC
>Mouse Jul. 2007 chr17:31983482-31983588 (+)
\tt GGCTGTCACAGGGAGCAAGCACATAGGGGACCGGGGACAGCTGGGGGGCCCTGCTGGCAGC
CAGATGAGGCGGCGGTAGAAGAGTGGTGCTGTAACTGGAGCAGC
= length = 107bp, identity = 72.0%, type = exon
>Human Mar. 2006 chr21:43661851-43662082 (+)
\verb|CTCTGCTGCTCTAGCACCTCCTAGCAGGCTCCAGCCCTCCCGGCTGCCGGCTGCCGCCG|\\
\verb|CCGTGCAGGCCTGGGGCTGGAAGGGGCTCAGGCCGCCCTGCTGGCC| \\
CGGCTGGCGGGGCCTGGCACACCTGGCGAGCCCCTTGATTTTGTTCAGTCCCAGA
AACCCTTTGGTCCGCGTGGTCTTCCTCAGCTGCTGCCGAAAGGCCTTCAGCC
>Mouse Jul. 2007 chr17:31983978-31984206 (+)
\verb|CTCTGCTGGTGCAGGACCTCTTCAAGTAGGCTCCTGCCCTCCCGATTGCTGGTCGTGCAG|\\
CGGACGGAGGA---CTGGCACACCTGGCGAGCCAACCCTTTGATCTTGTTCAGTCCCAGG
AACCCCTTGGTCCTCGCATTTTTCCTCAGCTGCTGCCGGAAGGCCTTCAGCC
  length = 232bp, identity = 77.6%, type = exon
>Human Mar. 2006 chr21:43662570-43662847 (+)
TGAGTCAGTGAGGTGTCCGACGCCCGCCGTCCCTCCTGGAAGCTGACAGGGAGCAGAACA
GCTCCTCCCAAGCCCCCTGAGCCTGCAGCACTGGGGTGGCGGACTGCGACCCCAGGAAG
{\tt GGCGAGGCCAGCCTGACCGGGGAGCAGCCCCAGCAGCCCCTGAGTGGCCGGGGTGCCA}
\tt CTGAGCCCGGGGGCTTTTGCTCGCAGAGAAGGTCAGACAACTGTCAGAGCTGGTTCCC
TCTGCAGGACTTGCCGTGGTGGAGGGGGAGACGACTAT
>Mouse Jul. 2007 chr17:31984842-31985119 (+)
TGAGTGAGAGGGTATCAGACGCTCTCCGTCCCTCCTGGAAGCTGACGGGAGGTAAGACG
\verb|GCTGTGCCCAGACCTGCCTGAGTCTGGAGCACAGGGGTGGCTGACTGTGATCCCAGGAAG|
GGCGAGGCCAATCTGACTGGAGAGCTGGTGCCCAGCAGCCCTGGGGTGGCCAGGCCACTG
TCCGAGGGACTCGCCGTGGCAGAGGAGGAGACAATTAT
  length = 278bp, identity = 76.3%, type = exon
>Human Mar. 2006 chr21:43663331-43663545 (+)
GGCGCGTGAGTGGGGAGAGCGGGTGGAGACCTCGGCCAGGGTGTGCCTCCGGCCCGTG
{\tt TCCTCACTGATGGCTGTTCCAGCAGGCTGCTTGGGGACACGGGCCGGGGCCGGAACACT}
CCGCTGCAGCTGGCATCCACCGGGAAGAACAAGGG
>Mouse Jul. 2007 chr17:31985579-31985793 (+)
GGAGGGTTGAGCGGGGAGAAATGGGTGGAGACTTCAGCCAATGTGTGCCTCCGGCCTGTG
{\tt TCCTCGCTGATAGCTGTGCCAGCAGACTGCTGGGGGGAGATGGATCGGTGCCGGAACACT}
CCACTGCAGTTGGTATCCAGGGGGAATAATAAGGG
  length = 215bp, identity = 81.4%, type = exon
>Human Mar. 2006 chr21:43663662-43663786 (+)
{\tt GGTCTGCGGCTGCGGGCACAGCAAGGCAGGTCGGAAAGGGTCGGTGGAAAGACCTTCCTG}
AGGCAC
>Mouse Jul. 2007 chr17:31985901-31986026 (+)
{\tt CACCTGAAGTGAGCTGTGGAGATCACAGTCTATCTCAGCCTGCAGGACAGACTGAGCCAA}
GGCCTGGGGCTGTGGGCACAGCAGAGAGGGCCGGAAAGGGTCACACGGGAGAATTTCTTG
AGGAAC
= length = 126bp, identity = 77.0%, type = exon
>Human Mar. 2006 chr21:43664167-43664313 (+)
CTCCAAACCACTGAGGTCCGAGGCTCCGAGGCCGCGGCTGCCTGGCAGGCCCGGGG-----
-CGGGCGCAC---TGGGCATTCCGATACTCCTTGAGCCGCTCAAGGAGGAGGTAATAAAT
GGCAGCAAAGTGGTTATAGCTGCTGTTTTGCAGTGA
>Mouse Jul. 2007 chr17:31986464-31986619 (+)
\verb|CCGGGATGAGGGCTTGGGCGCTTCGATGCTCCTTGAGGCGCTCGAGTAGGAGGTAGTAAAT|\\
GGCGGCAAAGTGGTTGTAGCTGCTGTTCTGCAGAGA
= length = 156bp, identity = 74.4%, type = exon
>Human Mar. 2006 chr21:43664542-43664765 (+)
\verb|CTCCACCGTCCTCTGCCGGTCCACGCCCAGGGTCTGCATGATACCCAGCGCCTGCTCATC|\\
GTAGTCGCCCAGGTTGGAGGTGTAGCTGTGTGCGGAGAAGGCGGGCCAGGCGGGTCCCGG
{\tt CAAGCAGGGCTCAGCCGCATCCACCGGTGCTGCCGGATCTGGGCGATGGTGATGCGCCT}
GGCGGGGTCCACCACCAGCATGCGGCGGATCAGGCTCTCACAGT
>Mouse Jul. 2007 chr17:31986873-31987096 (+)
\verb|CTCTATAGTCCGCTGCCGGTCGATGCCGAGGGCCTGCATGATCCCTAGCACCTGTTCGTT|\\
GTAGTCGCCCAGGTTGGAGGTGTAGCCTTGCATGTCGAAGGCAGGGTCATCCTGCTGCAG
```

GAGAGTGGGGTCGCCTGCATCCACCGGTGCTGCGGGATCTGGGCTATGGTGATGCGCTT

AGCGGGGTCCACGACCAGCATGCGTCTGATCAGCGTCTCACAGT = length = 224bp, identity = 78.1%, type = exon

```
>Human Mar. 2006 chr21:43665318-43665441 (+)
\tt CTTGAGACATGAAGAGGGGATGCGGAAGCGGCCCTCCAGCACCCGCTGTCTCAGCGTCG
GCAGGTTAGGCCCATCGAAGGGGAGAACCGCAGACCAGGACGTACAGCACCACGCCCA
>Mouse Jul. 2007 chr17:31987671-31987794 (+)
CTTGAGACATGAAGAAGGGGATGCGGAAGCGGCCCTCCAGTACCCGCTGTCTCAGCGTAG
GCAGGTTGGGCCCGTCGAAGGGGAGGGAGCCACAGACCAGGACGTACAGCACCACACCGA
= length = 124bp, identity = 92.7%, type = exon
>Human Mar. 2006 chr21:43665551-43665675 (+)
\verb|CCAGATGTCCAGCTGGGGGCCTTCATACTCCTTCCCCTCAAAGACTTCCGGGGCGGCATA||
CGGGGGGCTCCCACACCACGTGGACAGAGGCTCTCCTGACTTGTAGAAATTCCCAAATCC
>Mouse Jul. 2007 chr17:31987886-31988010 (+)
CCAGACGTCCAGCTGGGGACCCTCGTACTCCTTCCCCTCGAAGACTTCAGGGGCTGCATA
\tt CGGGGGGCTCCCACACCACGTGGACAGAGGCTCGCCTGGCTTGTAGAAATTCCCAAATCC
AAAAT
= length = 125bp, identity = 92.8%, type = exon
>Human Mar. 2006 chr21:43665946-43666107 (+)
\tt CTGCCAGCTTGATGTCCATGTTGCCATCCAGCAGGAGGTTCTCGGTCTTGAGGTCCCGGT
{\tt GGACGATGTGATGGTCGTGACAGTACTCCACGGCCGACAGGATTTGCCAGAACTTCTTCC}
GCGCCTCGTTCTCACTCAGGTGCCCGTTGGAAGTCAAATAAT
>Mouse Jul. 2007 chr17:31988180-31988341 (+)
\tt CTGCTAGCTTGATATCCATGTTGCTGTCCAGGAGCAGGTTCTCCGTCTTGAGGTCCCGGT
{\tt GGACAATGTGGTGGTTGTGGCAGTACTCCACGGCTGACAGAATCTGCCAGAACTTCTGCC}
{\tt TAGCCTCGTTTTCACTCAAGTGCCCGTTGGAAGTCAGATAAT}
= length = 162bp, identity = 87.7%, type = exon
>Human Mar. 2006 chr21:43666282-43666345 (+)
CAAACATTTCTCCATTTTTAGCAAATTCAGTGACGATGTAAAGCATGTCCTTTGTTTCCA
>Mouse Jul. 2007 chr17:31988478-31988541 (+)
{\tt CAAACATTTCTCCATTTTTTGCAAATTCTGTGACAATGTAGAGCATATCCTTTGTCTCCA}
= length = 64bp, identity = 90.6%, type = exon
>Human Mar. 2006 chr21:43669255-43669355 (+)
CTACTGTCCTTGCAAAAATAAACTAATGAAAACC-AGTAAGAGCAGCTGGCTTT--AAAG
TTTAATAATTATCTGCAAAGGCAGAAGTTTCCAGTTTCACTCAA
>Mouse Jul. 2007 chr17:31990715-31990816 (+)
CTACTGCACCC-C-AAGACACTTTAAGGAGACCTGGGAAAGAACAGCTGCTTTTTAAACG
TTTAGCAATCCTCTGCAAAGGCGGAAGTTTCCAGTTTCGCTCAA
= length = 104bp, identity = 71.2%, type = intron
>Human Mar. 2006 chr21:43669715-43669831 (+)
\verb|CTGGTAAAGCTTTATGATGTGTGGATGGTTCAGAAGCTTCATCAGCTGAACCTCACGATA||
GATTTTCTCCAAATTGCTTGAATCTAATCGTGTTTTATCAATTATTTTTATTGCAAC
>Mouse Jul. 2007 chr17:31991153-31991269 (+)
\tt CTGATAAAGCTTGATGATATTTGGGTGGTTCAAAAGTTTCATGAGCTGGACCTCCCGGTA
GATCTTCTCCAGATTGCTAGAATCTAACCGTGTCTTGTCAATTATTTTTATTGCAAC
= length = 117bp, identity = 85.5%, type = exon
>Human Mar. 2006 chr21:43670331-43670486 (+)
\verb|CTGCGTTTTGGTGACTCGATGCCGCGCAGCTTCACCACCGCGAAGTTGCCTTTGCCCAG|\\
\tt GGTCCGCTCGATGTCGTAAAAACCCACCCGGAGGGGCTTCTGCTGGCCCTGACCCTGGCC
CGCGGGGTCCGCCTGAACTCCGACATGATAACCAT
>Mouse Jul. 2007 chr17:31991839-31991994 (+)
\verb|CTGCGTTTTGGTGACTCGGTGCCGCCCAGCTTAACCACTGCAAAATTGCCTTTGCCCAG|\\
\tt GGTCCGTTCCACGTCGTAAAAGCCCACCCGGAGGGGCTTCTGCTGGCCCTGGCCAGTGCC
TGAGGGGACCGCACTGAACTCCGACATGATCACCAT
length = 156bp, identity = 88.5%, type = exon
>Human Mar. 2006 chr21:43670487-43670500 (+)
GGCTCCGCGCG-CAC
>Mouse Jul. 2007 chr17:31991995-31992009 (+)
GGCTTCGGGCCGCAC
= length = 15bp, identity = 73.3%, type = UTR
>Human Mar. 2006 chr21:43671318-43671422 (+)
CTCCGCCGCCACCGGAGCCCAGGCCAGGAAGCCGCCCGCTCGGCCGCTGGCGCTGCTC
GGGTGCCTACTGCTCCGGCTGCCGCCGCCGCTGCTGCTCCG
>Mouse Jul. 2007 chr17:31992617-31992721 (+)
\tt CTCCGCCGCCTCCGTGAGCCCGACCCGGGATGCCACCCGCTCGGCTGCTAGCTCTGCTC
\tt CGGTGCCGCCGTTCGCGCCGCCGCCGCCAACGCTGCCGCCACCG
  length = 105bp, identity = 74.3%, type = UTR
>Human Mar. 2006 chr21:43671490-43671709 (+)
\tt GGGCCGCCCATTGACGTCGCTTTGACGCCAGAGCGACGCGGGCGAGCGCCGGGCGGAG
GGCCGTTGCCCTGGCGACCGCGGGCCGGTGACGTCAGGGGC
>Mouse Jul. 2007 chr17:31992777-31992993 (+)
\verb|CCCGCCCCGGCCCCGCCCCGCACAAGCCCCGCCTCG-CCCGCCCCCCGCGGGCAG|
GGCCGTCGCCATGGCGACCGCGGG-CGGTGACGTCAGGGGC
  length = 221bp, identity = 78.3%, type = intergenic
```

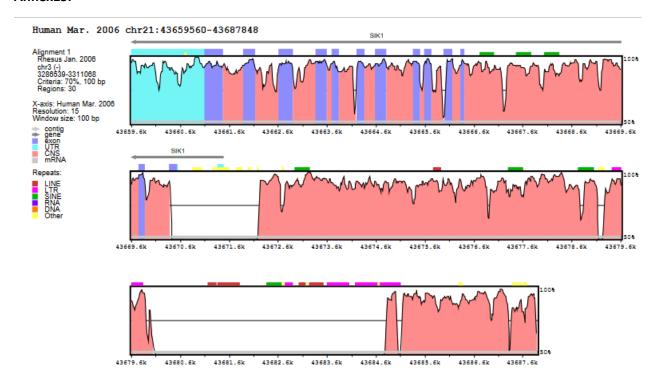
>Human Mar. 2006 chr21:43685080-43685176 (+)

```
ATGGTTTTTCTTAGT---TATTTGTCTCTGTGGGTTTTT
>Mouse Jul. 2007 chr17:32008698-32008798 (+)
\tt CTATCTTGTTTTGCTTTTTTTTTTTCCTTGGTGGGTATTT
= length = 101bp, identity = 70.3%, type = intergenic
>Human Mar. 2006 chr21:43685318-43685418 (+)
GCTAGTACTTCAGTCAGTGAATTGGCATTCGAAAGCGTGTCGTCATTAGTACAGACGTCA
GCGGTGAATGAGAAAGCAAAGAACCCGTGGCTGCACCTAAT
>Mouse Jul. 2007 chr17:32008943-32009042 (+)
GCTAGTGCTTCAGCGCGTGG-TTGGCATAAAGAAGTTTATCATCACTTCTACAGACGTCA
{\tt CAGGCGCATGTTAGAGCCAAGAAGCCATAGCTGCCCCTGAT}
  length = 101bp, identity = 70.3%, type = intergenic
>Human Mar. 2006 chr21:43685485-43685649 (+)
CTGGTCCAGGTGCAGGTTTTGAGTCCTCACTCAA-----AAATGAGATAAGGAATGTGA
CTTTGAACTCATTAGCCTTTTGATCAGGCTATGAACTAAAGGCAAATAGAACAGGTGGCC
TGACCCCTGCCAGAGACTGGCACTG-CCTGCGAGGTAGGAGCTCCCAGGTGG
>Mouse Jul. 2007 chr17:32009119-32009278 (+)
CTCCACCCAGTACA----CAAGTCCTCACTCAATCTTAAAAA-GTGATAAGAAATGTAA
\verb|CTTTGATCTGGCTAGCCTTTTGATCAAGCTGTGAATTAAAGGC-AATGGGCGGTGT--GC|\\
{\tt CAACCTCTCCCGGAGGCTGGCACTGCCCTTCGTGGGAGGAGCCA---GGTGG}
= length = 172bp, identity = 68.0%, type = intergenic
>Human Mar. 2006 chr21:43662672-43662847 (+)
GACTGCGACCCCAGGAAGGGCGAGGCCAGCCTGACCGGGGAGCAGGCCCCAGCAGCCCC
TGAGTGGCCGGGGTGCCACTGAGCCCCGCGGGGCTTTTGCTCGCAGAGAAGGTCAGACAA
\verb|CTGTCAGAGCTGGTTCCCTCTGCAGGACTTGCCGTGGTGGAGGGGGAGACGACTAT||
>Mouse Jul. 2007 chr17:31984944-31985119 (+)
GACTGTGATCCCAGGAAGGGCGAGGCCAATCTGACTGGAGAGCTGGTGCCCAGCAGCCCT
\tt GGGGTGGCCAGGCCATGCCAAGCCCTGCAGGACCTTCACTTGCAGAGAAGGGGAGGCAG
\verb|CTGTCGGAGCTGGTCCCTTCCGAGGGACTCGCCGTGGCAGAGGAGGAGACAATTAT||
= length = 176bp, identity = 76.1%, type = exon
>Human Mar. 2006 chr21:43663331-43663545 (+)
\tt GGCGCGGTGAGTGGGGAGAGGCGGGTGGAGACCTCGGCCAGGGTGTGCCTCCGGCCCGTG
TCCTCACTGATGGCTGTCCCAGCAGGCTGCTTGGGGACACGGGCCGGGGCCGGAACACT
CCGCTGCAGCTGGCATCCACCGGGAAGAACAAGGG
>Mouse Jul. 2007 chr17:31985579-31985793 (+)
\tt GGAGGGTTGAGCGGGGAGAATGGGTGGAGACTTCAGCCAATGTGTGCCTCCGGCCTGTG
{\tt TCCTCGCTGATAGCTGTGTCCAGCAGACTGCTGGGGGGAGATGGATCGGTGCCGGAACACT}
CCACTGCAGTTGGTATCCAGGGGGAATAATAAGGG
= length = 215bp, identity = 81.4%, type = exon
>Human Mar. 2006 chr21:43695585-43695695 (+)
\verb|CTTCCGCGTGTGGCCATCTGTCTTTCAGAAACCCTCTGGCAGAGGGACCCAGCAGATGAC| \\
ACGGGGCCGTTCACACTCTGAAACCTGCCTG-GAGTCAAAACACTGCTGGC
>Mouse Jul. 2007 chr17:32014877-32014980 (+)
\verb|CTTCC--GTTTGGCCATCTGTCTTCCAGAAACCCTCTGACAGC-ACATCCGGCAGATGCC|\\
TTGGGG--TGTTCCTCAT---AGACCTGTGTGGAAGTCAAAACATGGCTGGC
= length = 112bp, identity = 72.3%, type = UTR
```

## Conserved intervals sorted by the Human Mar. 2006 coordinates

```
***** Conserved Regions - Human Mar. 2006 chr21 (Mouse Jul. 2007 chr17) *****
  43659925 (31982234) to 43660040 (31982339) = 117bp at 76.1% UTR 43660184 (31982457) to 43660269 (31982548) = 93bp at 72.0% UTR 43660818 (31982939) to 43661021 (31983161) = 232bp at 71.1% UTR
                                                                                              93bp at 72.0%
232bp at 71.1%
  43661050 (31983228) to 43661293 (31983474) = 43661328 (31983482) to 43661425 (31983588) = 43661851 (31983978) to 43662082 (31984206) = 43662770 (31984804) to 43662847 (31985110) = 43662847 (31985110) = 43662847 (31985110)
                                                                                              <u>248bp</u> at 71.4%
                                                                                              107bp at
                                                                                                                72.0%
                                                                                              232bp at 77.6%
                                                                                                                            exon
                  (31984842) to 43662847 (31985119) = (31984944) to 43662847 (31985119) =
                                                                                              278bp at 76.3%
176bp at 76.1%
   43662570
                                                                                                                            exon
   43662672
                                                                                                                            exon
   43663331 (31985579) to 43663545 (31985793) = 43663331 (31985579) to 43663545 (31985793) = 43663662 (31985901) to 43663786 (31986026) =
                                                                                              215bp at 81.4%
                                                                                              215bp at 81.4%
126bp at 77.0%
   43663662
                                                                                                                            exon
                   (31986464) to 43664313 (31986619) = (31986873) to 43664765 (31987096) =
   43664167
                                                                                              <u>156bp</u> at
                                                                                                                74.4%
                                                                                                                            exon
                                                                                              224bp at 78.1%
124bp at 92.7%
   43664542
                                                                                                                            exon
   43665318
                  (31987671) to 43665441 (31987794) =
                                                                                                                            exon
                   (31987886) to 43665675 (31988010) = (31988180) to 43666107 (31988341) =
   43665551
43665946
                                                                                              125bp at
                                                                                                                92.8%
                                                                                                                            exon
                                                                                              162bp at 87.7%
                                                                                                                            exon
                  (31988478) to 43666345 (31988541) = (31990715) to 43669355 (31990816) = (31991153) to 43669831 (31991269) =
   43666282
                                                                                               <u>64bp</u> at 90.6%
                                                                                                                            exon
                                                                                              104bp at 71.2%
117bp at 85.5%
   43669255
   43669715
                                                                                                                            exon
                   (31991839) to 43670486 (31991994) = (31991995) to 43670500 (31992009) =
   43670331
43670487
                                                                                             156bp at 88.5%
15bp at 73.3%
                                                                                                                            exon
                                                                                                                            UTR
   43671318 (31992617) to 43671422 (31992721) =
                                                                                              105bp at 74.3%
                                                                                                                            UTR
                  (31992777) to 43671709 (31992993) = (32008698) to 43685176 (32008798) =
                                                                                              43671490
   43685080
                                                                                             101bp at 70.3% intergenic 172bp at 68.0% intergenic
   43685318 (32008943) to 43685418 (32009042) = 43685485 (32009119) to 43685649 (32009278) = 43695585 (32014877) to 43695695 (32014980) =
                                                                                             172bp at 68.0% inte
112bp at 72.3% UTR
```

#### Annex15.



# Annex16.

